



UNIVERSIDAD  
DE GRANADA

Facultad de Ciencias Localización de landmarks cefalométricos  
por medio de técnicas de few-shot learning

DOBLE GRADO EN INGENIERÍA INFORMÁTICA Y  
MATEMÁTICAS

TRABAJO DE FIN DE GRADO

# Localización de landmarks cefalométricos por medio de técnicas de few-shot learning y análisis de redes convolucionales

Presentado por:

Alejandro Borrego Megías

Tutor:

Pablo Mesejo Santiago

*DECSAI*

Guillermo Gómez Trenado

*DECSAI*

Javier Merí de la Maza

*Dpto Análisis Matemático*

Curso académico 2021-2022



# Localización de landmarks cefalométricos por medio de técnicas de few-shot learning y análisis de redes convolucionales

Alejandro Borrego Megías

Alejandro Borrego Megías *Localización de landmarks cefalométricos por medio de técnicas de few-shot learning y análisis de redes convolucionales.*

Trabajo de fin de Grado. Curso académico 2021-2022.

**Responsable de  
tutorización**

Pablo Mesejo Santiago  
*DECSAI*

Guillermo Gómez Trenado  
*DECSAI*

Javier Merí de la Maza  
*Dpto Análisis Matemático*

Doble Grado en Ingeniería  
Informática y Matemáticas

Facultad de Ciencias  
Universidad de Granada

#### DECLARACIÓN DE ORIGINALIDAD

D./Dña. Alejandro Borrego Megías

Declaro explícitamente que el trabajo presentado como Trabajo de Fin de Grado (TFG), correspondiente al curso académico 2021-2022, es original, entendida esta, en el sentido de que no ha utilizado para la elaboración del trabajo fuentes sin citarlas debidamente.

En Granada a 12 de julio de 2022

Fdo: Alejandro Borrego Megías



*Dedicatoria (opcional)*

*Ver archivo preliminares/dedicatoria.tex*





# Índice general

|   |             |
|---|-------------|
| <b>Agradecimientos</b>  | <b>XI</b>   |
| <b>Summary</b>  | <b>XIII</b> |
| <b>Introducción</b>   | <b>XV</b>   |
| <br>  |             |
| <b>I. Análisis de Redes Convolucionales</b>                                     | <b>1</b>    |
| <br>  |             |
| <b>1. Introducción</b>  | <b>3</b>    |
| 1.1. Introducción . . . . .   | 3           |
| 1.1.1. Notación . . . . .   | 6           |
| <br>  |             |
| <b>2. Modelización Matemática de una Red Neuronal Convolutional</b>             | <b>7</b>    |
| 2.1. De Fourier a las ondeletas de Littlewood-Paley . . . . .                   | 7           |
| 2.1.1. El módulo de la Transformada de Fourier . . . . .                        | 7           |
| 2.1.2. Alternativa: Las ondeletas . . . . .                                     | 12          |
| 2.1.3. La Transformada de Littlewood-Paley . . . . .                            | 15          |
| 2.1.4. Convenios para futuras secciones . . . . .                               | 18          |
| 2.2. El operador de dispersión sobre un camino ordenado . . . . .               | 19          |
| 2.2.1. Ejemplo para obtener coeficientes invariantes por traslaciones . . . . . | 20          |
| 2.2.2. El operador módulo. . . . .  | 21          |
| 2.2.3. Propiedades de un camino de frecuencias. . . . .                         | 22          |
| 2.2.4. Construcción del operador de dispersión. . . . .                         | 23          |
| 2.3. Propagador de dispersión y conservación de la Norma . . . . .              | 24          |
| 2.3.1. Proceso de dispersión del propagador. . . . .                            | 24          |
| 2.3.2. Diferencias y similitudes con una CNN . . . . .                          | 25          |
| 2.3.3. Relación con herramientas clásicas de visión por computador . . . . .    | 26          |
| 2.3.4. Operador no expansivo. . . . .   | 26          |
| 2.3.5. Conservación de la norma. . . . .  | 28          |
| 2.3.6. Conclusiones extraídas del teorema . . . . .                             | 31          |
| <br>  |             |
| <b>3. Invarianza por Traslaciones</b>   | <b>33</b>   |
| 3.1. No expansividad del operador de ventana en conjuntos de caminos . . . . .  | 33          |
| 3.2. Invarianza por traslaciones . . . . .                                      | 36          |
| <br>  |             |
| <b>4. Conclusiones</b>  | <b>41</b>   |
| 4.1. Elementos del texto . . . . .  | 42          |
| 4.1.1. Listas . . . . .   | 42          |
| 4.1.2. Tablas y figuras . . . . .   | 43          |
| 4.2. Entornos matemáticos . . . . .   | 43          |
| 4.3. Bibliografía e índice . . . . .  | 44          |

|  |           |
|--|-----------|
| <b>II. Localización de landmarks cefalométricos por medio de técnicas de few-shot learning</b> | <b>45</b> |
| <b>5. Introducción</b>   | <b>47</b> |
| 5.1. Introducción . . . . .  | 47        |
| 5.1.1. Descripción del problema . . . . .  | 47        |
| 5.1.2. Motivación . . . . .  | 48        |
| 5.1.3. Objetivos . . . . .   | 48        |
| <b>6. Fundamentos Teóricos</b>   | <b>49</b> |
| 6.1. Aprendizaje Automático . . . . .  | 49        |
| 6.1.1. Aprendizaje Supervisado . . . . .   | 50        |
| 6.1.2. Aprendizaje no Supervisado . . . . .  | 51        |
| 6.1.3. Nuestro Problema . . . . .  | 51        |
| 6.1.4. Gradiente Descendente . . . . .   | 51        |
| 6.2. Visión por Computador . . . . .   | 53        |
| 6.3. Deep Learning . . . . .   | 53        |
| 6.3.1. Redes Neuronales . . . . .  | 53        |
| 6.3.2. Back Propagation . . . . .  | 55        |
| 6.4. Redes Neuronales Convolucionales . . . . .  | 57        |
| 6.4.1. Capa Convolucional . . . . .  | 58        |
| 6.4.2. Capa de Pooling . . . . .   | 58        |
| 6.4.3. Capa Totalmente Conectada (Fully Conected) . . . . .                                    | 59        |
| 6.4.4. Batch Normalization . . . . .   | 60        |
| 6.4.5. Optimizador Adam . . . . .  | 60        |
| 6.4.6. Proceso de entrenamiento de una CNN . . . . .   | 60        |
| 6.4.7. Evolución de las CNN . . . . .  | 61        |
| 6.5. Autoencoders . . . . .  | 65        |
| 6.5.1. Introducción . . . . .  | 65        |
| 6.5.2. Evolución de los Autoencoders . . . . .   | 65        |
| 6.6. Técnicas empleadas . . . . .  | 68        |
| 6.6.1. Few-shot Learning y Data Augmentation . . . . .   | 69        |
| <b>7. Estado del Arte</b>  | <b>71</b> |
| <b>8. Materiales y Métodos</b>   | <b>73</b> |
| <b>9. Planificación e implementación</b>   | <b>75</b> |
| <b>10. Experimentación</b>   | <b>77</b> |
| <b>11. Conclusiones y Trabajos Futuros</b>   | <b>79</b> |
| <b>A. Primer apéndice</b>  | <b>81</b> |
| <b>Glosario</b>  | <b>83</b> |
| <b>Bibliografía</b>  | <b>85</b> |

# Agradecimientos

Agradecimientos del libro (opcional, ver archivo preliminares/agradecimiento.tex).



## Summary

An english summary of the project (around 800 and 1500 words are recommended).

File: preliminares/summary.tex



## Introducción

De acuerdo con la comisión de grado, el TFG debe incluir una introducción en la que se describan claramente los objetivos previstos inicialmente en la propuesta de TFG, indicando si han sido o no alcanzados, los antecedentes importantes para el desarrollo, los resultados obtenidos, en su caso y las principales fuentes consultadas.

Ver archivo preliminares/introduccion.tex





## **Parte I.**

### **Análisis de Redes Convolucionales**

Si el trabajo se divide en diferentes partes es posible incluir al inicio de cada una de ellas un breve resumen que indique el contenido de la misma. Esto es opcional.



# 1. Introducción

## 1.1. Introducción

Actualmente, las **Redes Neuronales Convolucionales (CNN<sup>1</sup>)** son una de las herramientas más usadas de la Inteligencia Artificial para tareas de Aprendizaje Automático (AA), de hecho son el principal objeto de estudio del **Deep Learning**, una subrama del AA en la que hoy en día se está invirtiendo mucho esfuerzo en investigar y de la que anualmente se publican muchos artículos que nos enseñan la gran potencia de las CNN para diversas tareas.

Destaca especialmente el excelente desempeño que tienen las CNN en el procesamiento de imágenes para tareas de clasificación, segmentación o incluso generación de nuevas imágenes. Es por ello que en el presente trabajo nos proponemos realizar una **modelización matemática** de estas CNN, para conocerlas mejor desde un punto de vista más teórico y **conocer algunas de sus principales propiedades** como la invarianza por traslaciones o frente a “*pequeñas*” deformaciones. Finalmente, trataremos de **demostrar** la invarianza por traslaciones.

En primer lugar vamos a definir el concepto de **Invarianza** como la capacidad de reconocer un objeto en una imagen incluso si su apariencia ha variado en algún sentido (mediante una rotación, una ligera deformación o una traslación). Esto es algo muy importante, pues esto indica que se preserva la identidad del objeto incluso a pesar de haberse sometido a ciertos cambios.

De esta forma definimos la **Invarianza por traslaciones** como la capacidad de reconocer la identidad de un objeto en una imagen incluso si este se ha desplazado. Esta propiedad es fundamental y sabemos que las CNN la verifican.



Figura 1.1.: Las tres estatuas deben identificarse como iguales, aunque se encuentren desplazadas.

Por otro lado, se conoce la **Invarianza frente a pequeñas deformaciones** (difeomorfismos) a la capacidad de reconocer la identidad de un objeto en una imagen a pesar de que este pueda haber sido alterado con pequeñas deformaciones.

Esto motiva el estudio de las representaciones de traslaciones e invarianzas en las funciones de  $L^2(\mathbb{R}^d)$ , que son Lipschitz-continuas por la acción de difeomorfismos y que mantienen

---

<sup>1</sup>Convolutional Neural Network

## 1. Introducción




Figura 1.2.: Acción de un difeomorfismo en una rejilla.




Figura 1.3.: Todas las imágenes deberían clasificarse como 5, pese a las deformaciones.



Figura 1.4.: Deformación excesiva que permite confundir el 1 con el 2 cuando se le aplica el difeomorfismo. Por eso nos centramos en “pequeñas” deformaciones, para no alterar la identidad del objeto en la imagen.

información de alta frecuencia para diferenciar entre distintos tipos de señales, con el objetivo de encontrar un operador que verifique todas estas propiedades y que presentaremos como la modelización matemática de una CNN.

De esta manera, la invarianza por traslaciones, entendida en el contexto de las imágenes

puede verse como trasladar cada pixel de la imagen en una misma dirección la misma distancia. En este sentido :

**Definición 1.1.**  $L_c f(x) = f(x - c)$  es la traslación de  $f \in L^2(\mathbb{R}^d)$  por  $c \in \mathbb{R}^d$ .

Así, decimos que un operador  $\Phi$  de  $L^2(\mathbb{R}^d)$  en un espacio de Hilbert  $\mathcal{H}$  es invariante por traslaciones si  $\Phi(L_c f(x)) = \Phi(f)$  para todo  $f \in L^2(\mathbb{R}^d)$  y para todo  $c \in \mathbb{R}^d$ . En el siguiente apartado trataremos el caso del módulo de la transformada de Fourier de  $f$  como un ejemplo de un operador invariante por traslaciones. Sin embargo, es conocido el hecho de que aparecen inestabilidades frente a deformaciones en las altas frecuencias, y el mayor reto es preservar la Lipschitz-continuidad en esta situación.

Para preservar la estabilidad en  $L^2(\mathbb{R}^d)$  queremos que  $\Phi$  sea no-expansiva.

**Definición 1.2.** Decimos que  $\Phi$  es no-expansiva si:

$$\forall (f, h) \in L^2(\mathbb{R}^d)^2 \quad \|\Phi(f) - \Phi(h)\|_{\mathcal{H}} \leq \|f - h\|$$

Por otro lado:

**Definición 1.3.** Una función diferenciable  $f : X \rightarrow \Omega$  dónde  $X$  y  $\Omega$  son variedades, es un “Difeomorfismo” si  $f$  es una biyección y su inversa  $f^{-1} : \Omega \rightarrow X$  es también diferenciable.

En nuestro caso, vamos a encargarnos de verificar la Lipschitz-continuidad relativa a la acción de pequeños difeomorfismos cercanos a las traslaciones. Dichos difeomorfismos transforman  $x \in \mathbb{R}^d$  en  $x - \tau(x)$  dónde  $\tau$  es el campo de desplazamiento.

**Definición 1.4.** Denotemos  $L_\tau f(x) = f(x - \tau(x))$  como la acción del difeomorfismo  $\mathbb{1} - \tau$  en  $f$ .

Por otro lado, la condición de Lipschitz es la siguiente:

**Definición 1.5.** Sea  $f : M \rightarrow N$  una función entre dos espacios métricos  $M$  y  $N$  con sus respectivas distancias  $d_M$  y  $d_N$ . Se dice que  $f$  satisface la condición de Lipschitz si  $\exists C > 0$  tal que:

$$d_N(f(x), f(y)) \leq C d_M(x, y), \quad \forall x, y \in M$$

En nuestro caso, la  $d_N$  que utilizaremos será la norma del espacio de Hilbert  $\mathcal{H}$  de llegada, pero necesitamos definir de alguna manera una distancia  $d_M$  entre los difeomorfismos  $\mathbb{1}$  y  $\mathbb{1} - \tau$  para escribir correctamente la condición de Lipschitz. Además, dado que el espacio de partida es  $L^2(\mathbb{R}^d)$  y los puntos que vamos a comparar son las funciones  $f$  y  $L_\tau f = f(x - \tau(x))$  sabemos que  $\|\Phi(f) - \Phi(L_\tau f)\|$  estará acotada por  $\|f\| d(\mathbb{1}, \mathbb{1} - \tau)$ , de manera que necesitamos definir una distancia entre el difeomorfismo  $\mathbb{1}$  y  $\mathbb{1} - \tau$ . Para ello, la topología débil<sup>2</sup> en los difeomorfismos  $C^2$  permite definir la siguiente aplicación, que utilizaremos como distancia:

**Definición 1.6.** Así, se define una distancia entre  $\mathbb{1} - \tau$  y  $\mathbb{1}$  en cualquier subconjunto compacto  $\Omega$  de  $\mathbb{R}^d$  como

$$d_\Omega(\mathbb{1}, \mathbb{1} - \tau) = \sup_{x \in \Omega} |\tau(x)| + \sup_{x \in \Omega} |\nabla \tau(x)| + \sup_{x \in \Omega} |H\tau(x)| \quad (1.1)$$

<sup>2</sup>recordemos que es la topología menos fina de un espacio normado que hace continuas todas las aplicaciones de su dual

## 1. Introducción

Dónde  $|\tau(x)|$  es la norma euclídea en  $\mathbb{R}^d$ ,  $|\nabla\tau(x)|$  la norma del supremo de la matriz  $\nabla\tau(x)$ , y  $|\mathcal{H}\tau(x)|$  la norma del supremo del Hessiano.

Así, podemos finalmente expresar la condición de Lipschitz que un operador debería satisfacer en nuestro caso:

**Definición 1.7.** Un operador invariante por traslaciones  $\Phi$  se dice “*Lipchitz-continuo*” por la acción de los difeomorfismos  $C^2$  si para cualquier compacto  $\Omega \subset \mathbb{R}^d$  existe una constante  $C$  tal que para todo  $f \in L^2(\mathbb{R}^d)$  con Soporte en  $\Omega$  y para todo  $\tau \in C^2(\mathbb{R}^d)$  se cumple:

$$\|\Phi(f) - \Phi(L_\tau f)\|_{\mathcal{H}} \leq C \|f\| \left( \sup_{x \in \mathbb{R}^d} |\nabla\tau(x)| + \sup_{x \in \mathbb{R}^d} |\mathcal{H}\tau(x)| \right) \quad (1.2)$$

con  $\|\nabla\tau\|_\infty + \|\mathcal{H}\tau\|_\infty < 1$  para asegurarnos de que la deformación sea invertible [TY05].

Debido a que  $\Phi$  es invariante a traslaciones, la cota superior de Lipschitz no depende de la amplitud máxima de traslación  $\sup_{x \in \mathbb{R}^d} |\tau(x)|$  de la métrica del difeomorfismo (1.1). Por otro lado la continuidad Lipschitz de (1.2) implica que  $\Phi$  es invariante por traslaciones globales, pero es mucho más fuerte.  $\Phi$  se ve poco afectada por los términos de primer y segundo grado de difeomorfismos que son traslaciones locales.

Una vez presentadas las principales herramientas con las que trabajaremos, en las futuras secciones veremos como para la elección de ciertos operadores como el módulo de la transformada de Fourier existen problemas para satisfacer la condición de Lipschitz en altas frecuencias. Para solucionar el problema se optará por utilizar transformadas de ondeletas, pero esto abre nuevos problemas como serán el hecho de que no son invariantes por traslaciones. Por ello será necesario componer la transformada con un operador no lineal que será el módulo para obtener coeficientes invariantes por traslaciones. Este nuevo operador que consistirá en una cascada de convoluciones de operadores no lineales y no conmutativos de manera que cada uno de ellos calcula el módulo de la transformada de ondeletas, y será este nuevo operador el que podremos interpretar como la modelización matemática de una CNN.

### 1.1.1. Notación

- $\|\tau\|_\infty := \sup_{x \in \mathbb{R}^d} |\tau(x)|$
- $\|\nabla\tau\|_\infty := \sup_{x \in \mathbb{R}^d} |\nabla\tau(x)|$
- $\|\mathcal{H}\tau\|_\infty := \sup_{x \in \mathbb{R}^d} |\mathcal{H}\tau(x)|$  dónde  $|\mathcal{H}\tau(x)|$  es la norma del tensor Hessiano.
- La norma en  $L^2(\mathbb{R}^d)$  de  $f$  lo denotamos  $\|f\|$ .
- La norma de  $f$  en  $L^1(\mathbb{R}^d)$  lo denotamos  $\|f\|_1 = \int |f(x)| dx$ .
- Se denota  $g \circ f(x) = f(gx)$  a la acción de un elemento del grupo  $g \in G$ .
- Un operador  $\mathcal{R}$  parametrizado por  $p$  es denotado por  $\mathcal{R}[p]$  y  $\mathcal{R}[\Omega] = \{\mathcal{R}[p]\}_{p \in \Omega}$ .

## 2. Modelización Matemática de una Red Neuronal Convolutiva

Nuestro primer objetivo será tratar de llegar a la modelización matemática de lo que es una CNN, para ello necesitamos en primer lugar definir un operador que denominaremos **propagador de dispersión** (PD) que será el que aplicaremos de forma recursiva en la cascada de convoluciones que modeliza una CNN, para ello explicaremos la problemática de elegir un operador *lipschitz-continuo* bajo la acción de difeomorfismos e *invariante por traslaciones*, para evitar problemas como las inestabilidades en altas frecuencias que se producen en las señales bajo la acción de difeomorfismos como ocurre si usamos la transformada de Fourier.

Tras esto veremos posibles alternativas para evitar que se produzcan estas inestabilidades, mediante el uso de bases de la transformada de ondeletas de **Littlewood-Paley**. En concreto con esta segunda alternativa obtendremos un operador que es **Lipschitz-continuo** bajo la acción de difeomorfismos.

Después, nuestra tarea será conseguir calcular coeficientes que sean invariantes por traslaciones, y para ello necesitaremos utilizar un operador no lineal como es el módulo.

Una vez tengamos un operador con todas las propiedades anteriores presentaremos el **PD**, y será la aplicación en cadena de este operador anterior sobre un “camino” de frecuencias y rotaciones el que definirá la modelización matemática de una Red Neuronal Convolutiva.

### 2.1. De Fourier a las ondeletas de Littlewood-Paley

#### 2.1.1. El módulo de la Transformada de Fourier

El análisis de Fourier tradicionalmente ha jugado un papel fundamental en el procesamiento de señales [Gon17], por lo que podría parecer un buen punto de partida para la construcción del **propagador de dispersión** emplear la **transformada de Fourier**, una de las herramientas matemáticas más potente en este campo. La intuición detrás de su fórmula es la de representar funciones no periódicas (pero que tienen área bajo la curva finita) como la integral de senos y cosenos multiplicados por una función que determina los pesos en cada instante. Formalmente tiene la siguiente expresión:

$$\hat{f}(\omega) := \int f(x)e^{-ix\omega} dx = \int f(x) [\cos x\omega - i \sin x\omega] dx.$$

Entre las propiedades más destacables de la transformada encontramos el hecho de que una función se puede recuperar sin pérdida de información a partir de su transformada de Fourier, lo cual nos permite poder trabajar en el “Dominio de Fourier”<sup>1</sup> ya que al calcular la integral, la función resultante sólo depende de  $\omega$  (la frecuencia), y posteriormente pasar de nuevo al dominio original de la función, aplicando la inversa de la transformada sin pérdida de información.

---

<sup>1</sup>También llamado “Dominio de Frecuencia”

Esto a priori es algo atractivo, pues nos permitiría trabajar en un dominio más sencillo y extraer conclusiones que podemos traducir al dominio original de la señal sin pérdida de información. Además, en el estudio de señales se suele emplear el módulo de la transformada de Fourier para evitar fases complejas en el análisis, de esta forma el operador que vamos a probar en primer lugar es:

**Definición 2.1.**  $\Phi(f) = |\widehat{f}|$  módulo de la transformada de Fourier.

Vamos a comprobar si se trata de un operador válido para nuestro propósito. Para ello necesitamos en primer lugar que sea un operador **Invariante por traslaciones**. Veamos que sí cumple esta propiedad.

**Lema 2.1.** El operador  $\Phi(f) = |\widehat{f}|$  es invariante por traslaciones.

*Demostración.* Para ello tenemos que ver que si definimos para cada  $c \in \mathbb{R}^d$ , la traslación  $L_c f(x) = f(x - c)$  se tiene que :

$$\widehat{L_c f}(w) = \int_{\mathbb{R}^d} L_c f(x) e^{-ixw} dx = \int_{\mathbb{R}^d} f(x - c) e^{-ixw} dx$$

Y realizando el cambio de variable  $x - c = y$  se tendría que:

$$\begin{aligned} \int_{\mathbb{R}^d} f(x - c) e^{-ixw} dx &= \int_{\mathbb{R}^d} f(y) e^{-i(y+c)w} dy = \\ &= \int_{\mathbb{R}^d} f(y) e^{-iyw} e^{-icw} dy = \\ &= \int_{\mathbb{R}^d} f(y) e^{-iyw} dy = e^{-icw} \widehat{f}(w) \end{aligned}$$

Por lo que se tiene que  $|\widehat{L_c f}(w)| = |e^{-icw}| |\widehat{f}(w)| = |\widehat{f}(w)|$  y entonces  $\Phi(f) = |\widehat{f}|$  es invariante a traslaciones.  $\square$

Sin embargo, la invarianza por traslaciones no es suficiente, necesitamos también que nuestro operador sea invariante frente a pequeñas deformaciones (difeomorfismos). De esta forma, un operador  $\Phi(f)$  diremos que es estable frente a deformaciones si verifica **Def. 1.7**. Sin embargo, esta propiedad no la verifica el módulo de la Transformada de Fourier, como podemos ver a continuación:

**Lema 2.2.** El módulo de la Transformada de Fourier no es estable frente a pequeñas deformaciones y no es "Lipschitz-continuo".

*Demostración.* Vamos a considerar la función  $\tau(x) := \epsilon x$  con  $0 < \epsilon < 1$ . De esta forma  $\|\nabla \tau(x)\|_\infty = \epsilon$  y  $\|H\tau(x)\|_\infty = 0$  con esto, la condición de Lipschitz debería ser

$$\left| \left| \widehat{f} \right| - \left| \widehat{L_\tau f} \right| \right| \leq c \|f\| (\|\nabla \tau\|_\infty + \|H\tau\|_\infty) \leq c \|f\| \epsilon$$

Vamos a ver un contraejemplo con una función de una dimensión por simplicidad.

Supongamos que tenemos  $f(x) = e^{i\zeta x} \Theta(x) = e^{i\zeta x} e^{-|x|}$ . Calculamos ahora  $|\widehat{f}|$  y  $|\widehat{L_\tau f}|$  teniendo en cuenta que :



$$\begin{aligned}
 |\widehat{f}(\omega)| &= \left| \int f(x) e^{-ix\omega} dx \right| \\
 &= \left| \int f(x) e^{-ix\omega} dx \right| \\
 &= \left| \int e^{i\xi x} e^{-|x|} e^{-ix\omega} dx \right| \\
 &= \left| \int e^{-ix(\xi-\omega)} dx \right| \\
 &= \left| \int e^{-|x|} [\cos x(\xi-\omega) - i \sin x(\xi-\omega)] dx \right|
 \end{aligned}$$

En el último paso podemos descomponer la integral en suma de dos, y para simplificar las operaciones llamamos  $\beta = (\xi - \omega)$ . Así, aplicando las siguientes fórmulas conocidas para el cálculo de integrales,

$$\int_{\mathbb{R}} \cos(\beta x) e^{-|x|} dx = \frac{1}{1 + \beta^2} \quad (2.1)$$

y

$$\int_{\mathbb{R}} \sin(\beta x) e^{-|x|} dx = 0 \quad (2.2)$$

a nuestro caso concreto, obtenemos que:

$$\begin{aligned}
 |\widehat{f}(\omega)| &= \left| \int \cos x \beta e^{-|x|} dx - i \int \sin x \beta e^{-|x|} dx \right| \\
 &= \frac{1}{1 + \beta^2} \\
 &= \frac{1}{1 + (\xi - \omega)^2}.
 \end{aligned}$$

Ahora pasamos a calcular  $|\widehat{L_\tau f}|$ :

$$\begin{aligned}
 |\widehat{L_\tau f}(\omega)| &= |\widehat{f}((1-\epsilon)\omega)| \\
 &= \left| \int f((1-\epsilon)x) e^{-ix\omega} dx \right| \\
 &= \left| \int e^{i\xi(1-\epsilon)x} e^{-(1-\epsilon)|x|} e^{-ix\omega} dx \right|.
 \end{aligned}$$

Ahora realizamos el siguiente cambio de variable

$$\tilde{x} = (1-\epsilon)x \implies x = \frac{\tilde{x}}{1-\epsilon}$$

## 2. Modelización Matemática de una Red Neuronal Convolutiva

$$d\tilde{x} = (1 - \epsilon)dx \implies dx = \frac{1}{(1 - \epsilon)}d\tilde{x}$$

y aplicando los cambios a lo que teníamos nos queda

$$\begin{aligned} |\widehat{L_\tau f}(\omega)| &= \frac{1}{(1 - \epsilon)} \left| \int f((1 - \epsilon)x) e^{-ix\omega} dx \right| \\ &= \frac{1}{(1 - \epsilon)} \left| \int e^{i\tilde{\zeta}\tilde{x}} e^{-|\tilde{x}|} e^{-i\frac{\tilde{x}}{(1 - \epsilon)}\omega} d\tilde{x} \right| \\ &= \frac{1}{(1 - \epsilon)} \left| \int e^{i\left[\frac{(1 - \epsilon)\tilde{\zeta} - \omega}{(1 - \epsilon)}\right]\tilde{x}} e^{-|\tilde{x}|} d\tilde{x} \right| \\ &= \frac{1}{(1 - \epsilon)} \left| \int e^{i\tilde{\beta}\tilde{x}} e^{-|\tilde{x}|} d\tilde{x} \right|, \end{aligned}$$

como podemos ver, llegamos a una integral que se resuelve de la misma manera que en el caso anterior haciendo uso de (2.1) y (2.2):

$$\begin{aligned} |\widehat{L_\tau f}(\omega)| &= \frac{1}{(1 - \epsilon)} \frac{1}{1 + \tilde{\beta}^2} \\ &= \frac{1}{(1 - \epsilon)} \frac{1}{1 + \left[\frac{(1 - \epsilon)\tilde{\zeta} - \omega}{(1 - \epsilon)}\right]^2}. \end{aligned}$$

De esta forma hemos obtenido que para nuestro caso concreto de  $f(x) = e^{i\tilde{\zeta}x} e^{-|x|}$ ,

$$\begin{aligned} \left\| |\widehat{L_\tau f}| - |\widehat{f}| \right\| &= \left\| \frac{1}{(1 - \epsilon)} \frac{1}{1 + \left[\frac{(1 - \epsilon)\tilde{\zeta} - \omega}{(1 - \epsilon)}\right]^2} - \frac{1}{1 + (\tilde{\zeta} - \omega)^2} \right\| \\ &\geq \left\| \frac{1}{1 + \left[\frac{(1 - \epsilon)\tilde{\zeta} - \omega}{(1 - \epsilon)}\right]^2} - \frac{1}{1 + (\tilde{\zeta} - \omega)^2} \right\| \\ &= \left( \int_{\mathbb{R}} \left| \frac{1}{1 + \left[\frac{(1 - \epsilon)\tilde{\zeta} - \omega}{(1 - \epsilon)}\right]^2} - \frac{1}{1 + (\tilde{\zeta} - \omega)^2} \right|^2 d\omega \right)^{1/2}. \end{aligned}$$

A continuación vamos a intentar aproximar el valor del módulo de la integral, para ello en primer lugar vamos a realizar el siguiente cambio de variable

$$t = \omega - \xi \implies \omega - (1 - \epsilon)\xi = \omega - \xi + \epsilon\xi = t + \epsilon\xi$$

$$dt = d\omega.$$

Así, obtenemos que:

$$\begin{aligned} \int_{\mathbb{R}} \left| \frac{1}{1 + (\xi - \omega)^2} - \frac{1}{1 + \left[ \frac{(1-\epsilon)\xi - \omega}{(1-\epsilon)} \right]^2} \right|^2 d\omega &\geq \left| \int_{\mathbb{R}} \left( \frac{1}{1 + (\xi - \omega)^2} - \frac{1}{1 + \left[ \frac{(1-\epsilon)\xi - \omega}{(1-\epsilon)} \right]^2} \right)^2 d\omega \right| \\ &= \left| \int_{\mathbb{R}} \left( \frac{1}{1 + t^2} - \frac{1}{1 + \left[ \frac{t + \epsilon\xi}{(1-\epsilon)} \right]^2} \right)^2 dt \right| \end{aligned}$$

Representando la gráfica  $g_1(t) = \frac{1}{1+t^2}$ , podemos ver cómo el valor de su integral se acumula en torno al origen de coordenadas, y en cambio  $g_2(t) = \frac{1}{1 + \left[ \frac{t + \epsilon\xi}{(1-\epsilon)} \right]^2}$  es una traslación y escalado

de la función anterior. De esta forma, si  $\epsilon\xi$  es muy grande, el área de la función  $g_2(t)$  será prácticamente cero en la región del espacio donde  $g_1(t)$  concentra su integral. Dicho de otra forma, las dos funciones tendrían soporte disjunto.

De esta forma, podemos tomar una constante  $M > 0$  tal que para un valor de  $\xi$  elevado se cumpla que:

$$\begin{aligned} \int_{\mathbb{R}} \left| \frac{1}{1 + (\xi - \omega)^2} - \frac{1}{1 + \left[ \frac{(1-\epsilon)\xi - \omega}{(1-\epsilon)} \right]^2} \right|^2 d\omega &\geq \int_{-M}^M (g_1(t) - g_2(t))^2 dt \\ &\approx \int_{-M}^M g_1(t)^2 dt. \end{aligned}$$

Y como  $\xi$  puede ser arbitrariamente grande, intuitivamente el intervalo en el que ambas funciones tienen soporte disjunto crece de forma indefinida lo cual nos permite realizar la siguiente aproximación teniendo en cuenta que  $g_1(t) = \widehat{f}$ :

$$\left\| |\widehat{f}| - |\widehat{L_\tau f}| \right\| \sim \|g_1(t)\| = \|f\|.$$

Dónde la última igualdad la hemos realizado gracias a la fórmula de Plancharel que en el caso de  $\mathbb{R}^d$  es:

$$\int_{\mathbb{R}^d} |f(x)|^2 dx = \int_{\mathbb{R}^d} |\widehat{f}(\omega)|^2 d\omega. \quad (2.3)$$

Luego hemos demostrado que en este caso particular el operador  $|\widehat{f}|$  no cumple la condición de Lipschitz, pues como hemos mencionado antes,  $\xi$  puede ser arbitrariamente grande y de

## 2. Modelización Matemática de una Red Neuronal Convolutiva

esta forma, que la diferencia anterior pueda ser todo lo grande que se quiera.




Figura 2.1.: Como podemos ver en la imagen, para los valores  $\epsilon = 0.1$ ,  $\xi = 100$  y  $M = 5$  ambas funciones tienen soporte casi disjunto de manera que la diferencia entre ellas en el intervalo  $[-5, 5]$  coincide prácticamente con la integral de  $g_1(t)$ .

□

Por esto, lo que haremos será reemplazar las ondas sinusoidales de la transformada de Fourier por funciones localizadas con un soporte mayor en altas frecuencias que nos permitan evitar estas complicaciones, que tendrán un mejor rendimiento en nuestro propósito. Estas funciones se denominan **ondeletas**.

### 2.1.2. Alternativa: Las ondeletas

Las ondeletas [Maloo] son pequeñas ondas estables bajo la acción de deformaciones, al contrario que las ondas sinusoidales de Fourier. Definiremos la transformada de ondeletas y veremos que calcula, mediante convoluciones con bases de ondeletas, coeficientes estables bajo la acción de difeomorfismos.

Al contrario que las bases de Fourier, las bases de ondeletas definen representaciones dispersas de señales regulares a trozos, que podrían incluir transiciones y singularidades. En las imágenes, los mayores coeficientes de las ondeletas se localizan en el entorno de las esquinas y en las texturas irregulares.

A modo de ejemplo vamos a ver la base de Haar que, aunque no sea la que utilicemos para construir nuestro propagador de dispersión, puede ayudar a entender mejor la filosofía de las ondeletas. Se construye a partir de la siguiente función:

$$\psi(t) = \begin{cases} 1 & 0 \leq t < 1/2 \\ -1 & 1/2 \leq t < 1 \\ 0 & \text{en otro caso} \end{cases}$$




Figura 2.2.: Representación gráfica de la ondeleta de Haar.

A esta ondeleta la denominamos **ondeleta Madre**, pues a partir de ella, podemos generar la siguiente base ortonormal

$$\left\{ \psi_{j,n}(t) = \frac{1}{\sqrt{2^j}} \psi\left(\frac{t - 2^j n}{2^j}\right) \right\}_{(j,n) \in \mathbb{Z}^2}$$

del espacio  $L^2(\mathbb{R})$  de señales con energía finita. Si recordamos, en este espacio la norma se define como

$$\|f\|^2 = \int_{-\infty}^{+\infty} |f(t)|^2 dt < +\infty.$$

Así, cualquier señal  $f$  de energía finita puede ser representada por los coeficientes que se obtienen mediante el producto interno en  $L^2(\mathbb{R})$  con la base anterior:

$$\langle f, \psi_{j,n} \rangle = \int_{-\infty}^{+\infty} f(t) \psi_{j,n}(t) dt$$

y puede recuperarse sumando en su base ortonormal:

$$f = \sum_{j=-\infty}^{+\infty} \sum_{n=-\infty}^{+\infty} \langle f, \psi_{j,n} \rangle \psi_{j,n}$$

Esto nos permite (igual que pasaba con el módulo de la Transformada de Fourier) trabajar en un dominio más sencillo que nos permite procesar la información con mayor rapidez y posteriormente reconstruir la señal a partir de los coeficientes sin perder información. Algunas propiedades serían:

## 2. Modelización Matemática de una Red Neuronal Convolutiva

- Cada ondeleta  $\psi_{j,n}$  tiene media 0 en su soporte  $[2^j n, 2^j(n+1)]$ .
- Si  $f$  es localmente regular y  $2^j$  es pequeño, entonces es casi constante en su intervalo y su coeficiente de ondeleta  $\langle f, \psi_{j,n} \rangle$  es prácticamente cero.
- los mayores coeficientes se localizan en los cambios bruscos de intensidad de señal, como pueden ser los bordes, las esquinas o las texturas en las imágenes.

Para el caso concreto de imágenes<sup>2</sup>, las bases de ondeletas ortonormales pueden construirse a partir de bases ortonormales en señales de una dimensión. Así, a partir de tres ondeletas  $\psi^1(x)$ ,  $\psi^2(x)$  y  $\psi^3(x)$  con  $x = (x_1, x_2) \in \mathbb{R}^2$ , dilatadas por el factor  $2^j$  y trasladadas por  $2^j n$  con  $n = (n_1, n_2) \in \mathbb{Z}^2$ , se construye una base ortonormal para el espacio  $L^2(\mathbb{R}^2)$ :

$$\left\{ \psi_{j,n}^k(x) = \frac{1}{\sqrt{2^j}} \psi^k\left(\frac{x - 2^j n}{2^j}\right) \right\}_{(j,n) \in \mathbb{Z}^2}$$

El soporte de la ondeleta  $\psi_{j,n}^k(x)$  es un cuadrado proporcional a la escala  $2^j$ . Las bases de ondeletas en dos dimensiones se discretizan para definir bases ortonormales de imágenes de  $N$  píxeles.

Del mismo modo que en una dimensión, los coeficientes de ondeletas  $\langle f, \psi_{j,n}^k \rangle$  serán pequeños si  $f(x)$  es regular, y serán grandes cerca de los cambios bruscos de frecuencias como en los bordes o esquinas de las imágenes, como podemos ver en [Figura 2.3](#). Los filtros resaltan los bordes en tres direcciones, horizontal (derecha) vertical (abajo) y en diagonal (abajo derecha).




Figura 2.3.: Ejemplos de aplicar la base de Haar a dos imágenes [[PJDoMo6](#)].

Volviendo al propósito de definir el propagador de dispersión, la ondeleta madre que elijamos y la base ortogonal que forme se verán afectadas normalmente por escalados y rotaciones, por lo tanto definimos:

**Definición 2.2.** Una ondeleta madre escalada por un factor  $2^{-j}$  con  $j \in \mathbb{Z}$  y rotada por  $r \in G$  siendo  $G$  el grupo finito de rotaciones, se escribe:

$$\psi_{2^j r}(x) = 2^{dj} \psi(2^j r^{-1} x).$$

<sup>2</sup>ver por ejemplo sección 1.1 de [[Maloo](#)]

Su transformada de Fourier es  $\widehat{\psi_{2^j r}}(\omega) = \widehat{\psi}(2^j r^{-1}\omega)$ .

La transformada de dispersión que usaremos tendra una base de ondeletas generada por una ondeleta madre del tipo:

$$\psi(x) = e^{i\eta x} \Theta(x)$$

Donde  $\widehat{\Theta}(x)$  es una función real centrada en una bola de baja frecuencia en  $x = 0$ , cuyo radio es del orden de  $\pi$ .

Y como podemos ver:

$$\widehat{\psi}(\omega) = \int_{\mathbb{R}^d} e^{i\eta x} \Theta(x) e^{-i\omega x} dx = \int_{\mathbb{R}^d} \Theta(x) e^{ix(\omega - \eta)} dx = \widehat{\Theta}(\omega - \eta).$$

Por lo tanto,  $\widehat{\psi}(\omega)$  es real y centrada en una bola de mismo radio pero centrada en  $\omega = \eta$  que tras el escalado y rotación:

$$\widehat{\psi}_\lambda(\omega) = \widehat{\Theta}(\lambda^{-1}\omega - \eta),$$

donde  $\lambda = 2^j r \in 2^{\mathbb{Z}} \times G$ .

Por lo tanto  $\widehat{\psi}_\lambda(\omega)$  recubre una bola centrada en  $\lambda^{-1}\eta$  con radio proporcional a  $|\lambda| = 2^j$ .

### 2.1.3. La Transformada de Littlewood-Paley

Una vez conocemos un poco más en profundidad las ondeletas y su funcionamiento, pasamos a presentar la **Transformada de ondeleta de Littlewood-Paley**, que es la que emplearemos para construir el propagador de dispersión.

Se trata de una representación redundante que calcula convoluciones para todo  $x \in \mathbb{R}^d$  sin realizar sub-muestreo:

$$\forall x \in \mathbb{R}^d \quad W[\lambda]f(x) = f * \psi_\lambda(x) = \int f(u) \psi_\lambda(x - u) du.$$

Dónde  $*$  denota la operación de convolución.

Calculamos su transformada de Furier, para ello tendremos en cuenta el teorema de Convolución de la Transformada de Fourier, el cual dice:

**Teorema 2.1.** Sean  $f$  y  $g$  dos funciones integrables.

Si

$$h(x) = (f * g)(x) = \int f(y)g(x - y)dy$$

Entonces:

$$\widehat{h}(\omega) = \widehat{f}(\omega)\widehat{g}(\omega)$$

y

$$h(x) = (f * g)(x) = \int \widehat{f}(\omega)\widehat{g}(\omega)e^{-i\Omega x}d\omega$$

## 2. Modelización Matemática de una Red Neuronal Convolutiva

De esta manera, se tiene que:

$$W[\lambda]f(\omega) = \widehat{f}(\omega)\widehat{\psi}_\lambda(\omega) = \widehat{f}(\omega)\widehat{\psi}(\lambda^{-1}\omega).$$

Además, teniendo en cuenta la propiedad que nos dice que si la función  $f$  es real, entonces su transformada coincide con el conjugado complejo  $\widehat{f}(-\omega) = \overline{\widehat{f}(\omega)}$  podemos ver que:

- si  $\widehat{\psi}(\omega)$  y  $f$  son reales entonces  $W[-\lambda]f = \overline{W[\lambda]f}$ , utilizando la misma propiedad de antes. Además, si denotamos por  $G^+$  al cociente de  $G$  con  $\{-1, 1\}$ , conjunto en el cual las dos rotaciones  $r$  y  $-r$  son equivalentes, sería suficiente calcular  $W[2^j r]f$  para las rotaciones "positivas" de  $G^+$ .
- En cambio, si  $f$  fuese compleja, entonces  $W[2^j r]f$  tendría que calcularse para todo  $r \in G$ .

La transformada de Littlewood-Paley a una cierta escala  $2^j$  sólo mantiene las ondeletas de frecuencias  $2^j > 2^{-j}$  pues el resto de ondeletas de la base no tendrían soporte. De esta forma, las bajas frecuencias que no son cubiertas por estas ondeletas vienen dadas por un promedio en el dominio proporcional a  $2^j$ :

$$A_j f = f * \phi_{2^j} \text{ con } \phi_{2^j}(x) = 2^{-dj} \phi(2^{-j}x).$$

Así, si  $f$  fuese real, entonces la transformada de ondeleta tendría la siguiente expresión:

$$W_j f = \{A_j f, (W[\lambda]f)_{\lambda \in \Lambda_j}\}$$

Es decir, estaría formada por el promedio de todas las ondeletas de la base que no tienen soporte a la escala fijada  $2^j$ , y el conjunto de coeficientes producidos al convolucionar cada elemento de la base con  $2^j > 2^{-j}$  con la señal  $f$ . Para denotar esto indexamos por  $\Lambda_j = \{\lambda = 2^j r : r \in G^+, 2^j > 2^{-j}\}$ .

Su norma sería:

$$\|W_j f\|^2 = \|A_j f\|^2 + \sum_{\lambda \in \Lambda_j} \|W[\lambda]f\|^2.$$

Si  $j = \infty$  entonces todas las ondeletas de la base obtendrían coeficientes no nulos y por lo tanto

$$W_\infty f = \{W[\lambda]f\}_{\lambda \in \Lambda_\infty},$$

con  $\Lambda_\infty = 2^{\mathbb{Z}} \times G^+$ .

Su norma en este caso sería

$$\|W_\infty f\|^2 = \sum_{\lambda \in \Lambda_\infty} \|W[\lambda]f\|^2.$$

En el caso en que  $f$  sea compleja, se incluyen todas las rotaciones  $W_j f = \{A_j f, (W[\lambda]f)_{-\lambda, \lambda \in \Lambda_j}\}$  y  $W_\infty f = \{W[\lambda]f\}_{-\lambda, \lambda \in \Lambda_\infty}$ .

La siguiente proposición da una condición estándar de Littlewood-Paley para que  $W_j$  sea unitario.



**Proposición 2.1.** Para cualquier  $J \in \mathbb{Z}$  o  $J = \infty$ ,  $W_J$  es unitario en el espacio de funciones reales o complejas de  $L^2(\mathbb{R}^d)$  si y sólo si para casi todo  $\omega \in \mathbb{R}^d$ :

$$\beta \sum_{j=-\infty}^{\infty} \sum_{r \in G} |\widehat{\psi}(2^{-j}r^{-1}\omega)|^2 = 1 \quad y \quad |\widehat{\phi}(\omega)|^2 = \beta \sum_{j=-\infty}^0 \sum_{r \in G} |\widehat{\psi}(2^{-j}r^{-1}\omega)|^2, \quad (2.4)$$

Dónde  $\beta = 1$  para funciones complejas y  $\beta = \frac{1}{2}$  para funciones reales.

*Demostración.* Si  $f$  es una función compleja,  $\beta = 1$ , y vamos a demostrar que (2.4) es equivalente a :

$$\forall J \in \mathbb{Z} \quad \left| \widehat{\phi}(2^J\omega) \right|^2 + \sum_{j > -J, r \in G} \left| \widehat{\psi}(2^{-j}r^{-1}\omega) \right|^2 = 1. \quad (2.5)$$

Para ello partimos de que si  $\beta = 1$  se tiene sustituyendo en (2.4) que:

$$\sum_{j=-\infty}^{\infty} \sum_{r \in G} |\widehat{\psi}(2^{-j}r^{-1}\omega)|^2 = 1 \quad y \quad |\widehat{\phi}(\omega)|^2 = \sum_{j=-\infty}^0 \sum_{r \in G} |\widehat{\psi}(2^{-j}r^{-1}\omega)|^2.$$

Si ahora sumamos  $\sum_{j=0}^{\infty} \sum_{r \in G} |\widehat{\psi}(2^{-j}r^{-1}\omega)|^2$  en el segundo término obtenemos:

$$|\widehat{\phi}(\omega)|^2 + \sum_{j=0}^{\infty} \sum_{r \in G} |\widehat{\psi}(2^{-j}r^{-1}\omega)|^2 = 1.$$

Por otro lado si vamos a la expresión a la que queremos llegar se tiene que:

$$\forall J \in \mathbb{Z} \quad \left| \widehat{\phi}(2^J\omega) \right|^2 + \sum_{j > -J, r \in G} \left| \widehat{\psi}(2^{-j}r^{-1}\omega) \right|^2 = 1 \iff \forall J \in \mathbb{Z} \quad \left| \widehat{\phi}(2^J\omega) \right|^2 = \sum_{j=-\infty}^{-J} \sum_{r \in G} |\widehat{\psi}(2^{-j}r^{-1}\omega)|^2.$$

Con lo que si demostramos esto último tendríamos que (2.4) y (2.5) son equivalentes para el caso  $\beta = 1$ .

$$\begin{aligned} \left| \widehat{\phi}(2^J\omega) \right|^2 &= \sum_{j=-\infty}^0 \sum_{r \in G} |\widehat{\psi}(2^{-j}r^{-1}2^J\omega)|^2 \\ &= \sum_{j=-\infty}^0 \sum_{r \in G} |\widehat{\psi}(2^{J-j}r^{-1}\omega)|^2 \\ &= \sum_{j=-\infty}^{-J} \sum_{r \in G} |\widehat{\psi}(2^{-j}r^{-1}\omega)|^2 \end{aligned}$$

con lo que queda demostrado que (2.4) y (2.5) son equivalentes. Teniendo en cuenta que  $\widehat{W[2^Jr]} f(\omega) = \widehat{f}(\omega) \widehat{\psi}_{s^Jr}(\omega)$ , multiplicando (2.5) por  $|\widehat{f}(\omega)|^2$  obtenemos:

$$\forall J \in \mathbb{Z} \quad \left| \widehat{\phi}(2^J\omega) \right|^2 |\widehat{f}(\omega)|^2 + \sum_{j > -J, r \in G} \left| \widehat{f}(\omega) \right|^2 \left| \widehat{\psi}(2^{-j}r^{-1}\omega) \right|^2 = \left| \widehat{f}(\omega) \right|^2.$$

## 2. Modelización Matemática de una Red Neuronal Convolutiva

Si ahora integramos en ambos miembros en  $\mathbb{R}^d$  obtenemos:

$$\int_{\mathbb{R}^d} \left( |\hat{\phi}(2^J \omega)|^2 |\hat{f}(\omega)|^2 + \sum_{j > -J, r \in G} |\hat{f}(\omega)|^2 |\hat{\psi}(2^{-j} r^{-1} \omega)|^2 \right) d\omega = \int_{\mathbb{R}^d} |\hat{f}(\omega)|^2 d\omega.$$

Si la aplicamos (2.3) se obtiene:

$$\int_{\mathbb{R}^d} \left( |\phi(2^J \omega)|^2 |f(\omega)|^2 + \sum_{j > -J, r \in G} |f(\omega)|^2 |\psi(2^{-j} r^{-1} \omega)|^2 \right) d\omega = \int_{\mathbb{R}^d} |f(\omega)|^2 d\omega.$$

Si ahora recordamos la expresión (2.6), tenemos que la expresión anterior equivale a:

$$\|A_J f\|^2 + \sum_{\lambda \in \Lambda_J} \|W[\lambda] f\|^2 = \|W_J f\|^2 = \|f\|^2,$$

que es válido para todo  $J$  y en particular también cuando  $J = \infty$ .

Recíprocamente, si tenemos que  $\|W_J f\|^2 = \|f\|^2$  entonces (2.5) se verifica para casi todo  $\omega$ . De no ser así podríamos contruir una función  $f$  no nula cuya transformada de fourier  $\hat{f}$  tuviera soporte en el dominio de  $\omega$  dónde (2.5) no fuera válido, y en estos casos al aplicar la fórmula de Plancherel se verificaría que  $\|W_J f\|^2 \neq \|f\|^2$  contradiciendo la hipótesis. Y como la expresión (2.5) era equivalente a la que nos daba el teorema tenemos demostrado el resultado para el caso en que  $f$  sea compleja.

Si ahora  $f$  es real entonces  $|\hat{f}(\omega)| = |\hat{f}(-\omega)|$  lo que implica que  $\|W[2^j r] f\| = \|W[-2^j r] f\|$ . Por lo que  $\|W_J f\|$  permanece constante si restringimos  $r$  a  $G^+$  y multiplicando  $\psi$  por  $\sqrt{2}$  se obtiene la condición (2.4) con  $\beta = \frac{1}{2}$ .  $\square$

### 2.1.4. Convenios para futuras secciones

Llegados a este punto, ya tenemos la transformada de ondeletas que vamos a utilizar para la construcción del PD, ahora vamos a establecer algunas características que impondremos a los distintos elementos que la componen y que usaremos de ahora en adelante:

- $\hat{\psi}$  es una función real que satisface la condición (2.4). Lo que implica que  $\hat{\psi}(0) = \int \psi(x) dx = 0$  y  $|\hat{\phi}(r\omega)| = |\hat{\phi}(\omega)| \quad \forall r \in G$ .
- $\hat{\phi}(\omega)$  es real y simétrica, por lo que  $\phi$  también lo será y  $\phi(rx) = \phi(x) \quad \forall r \in G$ .
- Suponemos que  $\phi$  y  $\psi$  son dos veces diferenciables y su decrecimiento así como el de sus derivadas de primer y segundo orden es  $O((1 + |x|)^{-d-2})$ .

Un cambio de variable en la integral de la transformada de ondeleta nos muestra que si  $f$  se escala y rota,  $2^l g \circ f = f(2^l g x)$  con  $2^l g \in 2^{\mathbb{Z}} \times G$ , entonces la transformada de ondeleta se escala y rota de acuerdo a:

$$W[\lambda](2^l g \circ f) = 2^l g \circ W[2^{-l} g \lambda] f.$$

Como  $\phi$  es invariante a traslaciones en  $G$ , podemos comprobar que  $A_J$  conmuta con las rotaciones de  $G$ :  $A_J(g \circ f) = g \circ A_J f \quad \forall g \in G$ .

## 2.2. El operador de dispersión sobre un camino ordenado

La transformada de Littlewood-Paley definida anteriormente es Lipschitz-continua bajo la acción de difeomorfismos, porque las ondeletas son funciones regulares y localizadas. Sin embargo, todavía no es invariante a traslaciones y  $W[\lambda]f = f * \psi_\lambda$  se traslada cuando lo hace  $f$ . Así, nuestro próximo objetivo será conseguir calcular coeficientes que sean invariantes a traslaciones, que permanezcan estables bajo la acción de difeomorfismos y que retengan la información en altas frecuencias que proporcionan las ondeletas, reuniendo todas estas características tendríamos el operador que necesitamos para la construcción del PD.

Los coeficientes invariantes por traslaciones los obtendremos gracias a la acción de un operador no lineal aplicando el siguiente lema:

**Lema 2.3.** Si  $U[\lambda]$  es un operador definido en  $L^2(\mathbb{R}^d)$ , no necesariamente lineal pero que conmuta con traslaciones, entonces  $\int_{\mathbb{R}^d} U[\lambda]f(x)dx$  es invariante a traslaciones si es finito.

*Demostración.* Sea  $f \in L^2(\mathbb{R}^d)$ ,  $c \in \mathbb{R}^d$  y  $L_c f(x) = f(x - c)$  una traslación de  $f$ , como  $U[\lambda]f$  conmuta con traslaciones se tiene que:

$$\begin{aligned} U[\lambda]L_c f(x) &= U(f(x - c)) \\ &= U(f)(x - c) \\ &= L_c U[\lambda]f(x) \end{aligned}$$

Vamos a comprobar ahora que si  $\int_{\mathbb{R}^d} U[\lambda]f(x)dx$  es finito, entonces la integral es invariante a traslaciones. En otras palabras, queremos comprobar que :

$$\int_{\mathbb{R}^d} U[\lambda]L_c f(x)dx = \int_{\mathbb{R}^d} U[\lambda]f(x)dx$$

Para ello, si tenemos en cuenta la conmutatividad del operador  $U[\lambda]$  se tiene que

$$\begin{aligned} \int_{\mathbb{R}^d} U[\lambda]L_c f(x)dx &= \int_{\mathbb{R}^d} U[\lambda](f(x - c))dx \\ &= \int_{\mathbb{R}^d} U[\lambda](f)(x - c)dx. \end{aligned}$$

Y tras esto basta tener en cuenta el cambio de variable  $y = x - c$  que tiene Jacobiano  $J = 1$  y se tendría que en la expresión anterior

$$\int_{\mathbb{R}^d} U[\lambda](f)(x - c)dx = \int_{\mathbb{R}^d} U[\lambda](f)(y)dy.$$

Por lo que la integral es invariante por traslaciones. □

## 2. Modelización Matemática de una Red Neuronal Convolutiva

En nuestro caso  $W[\lambda]f = f * \psi_\lambda$  es un ejemplo trivial de este lema, pues se trata de un operador que conmuta con traslaciones y  $\int_{\mathbb{R}^d} f * \psi(x)dx = 0$  porque  $\int_{\mathbb{R}^d} \psi(x)dx = 0$ .

Esto nos enseña, que para obtener un operador invariante por traslaciones y no trivial  $U[\lambda]f$ , es necesario componer  $W[\lambda]$  con un operador extra  $M[\lambda]$  que sea "no lineal", y que se conoce como "demodulación", que transforma  $W[\lambda]f$  en una función de menor frecuencia con integral distinta de cero. Además, la elección de  $M[\lambda]$  debe preservar la Lipschitz-continuidad bajo la acción de difeomorfismos. En resumen, queremos un operador no lineal que produzca coeficientes invariantes por traslaciones no triviales y que además conserve la Lipschitz-continuidad.

Vamos a poner un ejemplo para entender mejor lo que se ha comentado anteriormente:

### 2.2.1. Ejemplo para obtener coeficientes invariantes por traslaciones

Si la **ondeleta madre** fuese  $\psi(x) = e^{i\eta x}\Theta(x)$ , entonces los elementos de la base tendrían la forma  $\psi_\lambda(x) = e^{i\lambda\eta x}\Theta_\lambda(x)$ , y por lo tanto

$$\begin{aligned} W[\lambda]f(x) &= f * \phi_\lambda(x) \\ &= f * e^{i\lambda\eta x}\Theta_\lambda(x) \\ &= e^{i\lambda\eta x}(e^{-i\lambda\eta x}f(x) * \Theta_\lambda(x)) \\ &= e^{i\lambda\eta x}(f^\lambda * \Theta_\lambda(x)), \end{aligned} \tag{2.6}$$

con  $f^\lambda(x) = e^{-i\lambda\eta x}f(x)$ .

En este caso, se podría obtener un operador invariante por traslaciones si se cancela el término de modulación  $e^{i\lambda\eta x}$  con una función  $M[\lambda]$  pertinente. Por ejemplo:

$$M[\lambda]h(x) = e^{-i\lambda\eta x}e^{-i\Phi(\widehat{h}(\lambda\eta))}h(x).$$

Dónde  $\Phi(\widehat{h}(\lambda\eta))$  es la fase compleja de  $\widehat{h}(\lambda\eta)$ . Este registro de fase no lineal garantiza que  $M[\lambda]$  conmuta con las traslaciones, ya que:

$$\begin{aligned} \int_{\mathbb{R}^d} M[\lambda]W[\lambda]f(x)dx &= \int_{\mathbb{R}^d} e^{-i\lambda\eta x}e^{-i\Phi(\widehat{W[\lambda]f}(\lambda\eta))} \left( e^{i\lambda\eta x} \left( e^{-i\lambda\eta x}f * \Theta_\lambda(x) \right) \right) dx \\ &= e^{-i\Phi(\widehat{f}(\lambda\eta)\widehat{\psi}_\lambda(\lambda\eta))} \int_{\mathbb{R}^d} e^{-i\lambda\eta x}f * \Theta_\lambda(x)dx \\ &= e^{-i\Phi(\widehat{f}(\lambda\eta)\widehat{\psi}_\lambda(\lambda\eta))} \int_{\mathbb{R}^d} e^{-i\lambda\eta x}f(x)dx \int_{\mathbb{R}^d} \Theta_\lambda(x)dx \\ &= e^{-i\Phi(\widehat{f}(\lambda\eta)\widehat{\psi}_\lambda(\lambda\eta))} \cdot \widehat{f}(\lambda\eta) \cdot \widehat{\Theta}_\lambda(0) \\ &= \left| \widehat{f}(\lambda\eta) \cdot \widehat{\Theta}_\lambda(0) \right|^2 \\ &= \left| \widehat{f}(\lambda\eta) \right|^2 \left| \widehat{\Theta}_\lambda(0) \right|^2 \\ &= \left| \widehat{f}(\lambda\eta) \right|^2 \left| \widehat{\Theta}(0) \right|^2 \end{aligned}$$

que como podemos ver, la integral tiene un valor no trivial y por otra parte obtenemos el módulo de la transformada que como habíamos visto [Lema 2.1](#) era invariante por traslaciones. No obstante, no utilizaremos este operador para nuestro propósito pues además de ser complejo no verifica la invarianza bajo la acción de difeomorfismos.

### 2.2.2. El operador módulo.

En nuestro caso, para preservar la Lipschitz-continuidad bajo la acción de difeomorfismos necesitamos que  $M[\lambda]$  conmute con estos y que además sea no expansiva para garantizar la estabilidad en  $L^2(\mathbb{R}^d)$ . Se puede comprobar que entonces  $M[\lambda]$  tiene que ser necesariamente un operador punto a punto [\[J.B12\]](#), lo que significa que el operador  $M[\lambda]h(x)$  que buscamos dependería únicamente del valor de  $h$  en el punto  $x$ .

Para obtener mejores propiedades vamos a imponer también que  $\|M[\lambda]h\| = \|h\| \quad \forall h \in L^2(\mathbb{R}^d)$ , lo que implica entonces que  $|M[\lambda]h| = |h|$ , ya que:

$$\begin{aligned} \|M[\lambda]h\| = \|h\| &\iff \left( \int_{\mathbb{R}^d} |M[\lambda]h(x)|^2 dx \right)^{\frac{1}{2}} = \left( \int_{\mathbb{R}^d} |h(x)|^2 dx \right)^{\frac{1}{2}} \\ &\iff \int_{\mathbb{R}^d} |M[\lambda]h(x)|^2 dx = \int_{\mathbb{R}^d} |h(x)|^2 dx \\ &\iff |M[\lambda]h(x)|^2 = |h(x)|^2 \\ &\iff |M[\lambda]h(x)| = |h(x)| \end{aligned}$$

Para satisfacer todas las restricciones, utilizaremos el operador  $M[\lambda]h = |h|$ , que además elimina todas las variaciones de fase [\[BM13\]](#). Se obtiene entonces de (2.6) que este módulo transforma  $W[\lambda]f$  en una señal de menor frecuencia que la original:

$$M[\lambda]W[\lambda]f = |W[\lambda]f| = |f^\lambda * \Theta_\lambda|.$$

Vamos a visualizar con un ejemplo cómo al interferir dos señales con este operador, la frecuencia resultante es menor que cada una de las originales.

Por ejemplo, si

$$f(x) = \cos(\xi_1 x) + a \cos(\xi_2 x)$$

dónde  $\xi_1$  y  $\xi_2$  están en la banda de frecuencia cubierta por  $\hat{\psi}_\lambda$ , entonces al aplicar el operador módulo:

$$|f * \psi_\lambda(x)| = 2^{-1} |\hat{\psi}_\lambda(\xi_1) + a \hat{\psi}_\lambda(\xi_2) e^{i(\xi_2 - \xi_1)x}|$$

que oscila entre la frecuencia de interferencias  $|\xi_2 - \xi_1|$ , que como vemos es menor que  $|\xi_1|$  y  $|\xi_2|$ .

De esta manera, por la forma en que hemos construido el operador  $U[\lambda]f$  la integración de  $\int_{\mathbb{R}^d} U[\lambda]f(x) dx = \int_{\mathbb{R}^d} |f * \psi_\lambda(x)| dx$  es invariante por traslaciones pero elimina todas las altas frecuencias de  $|f * \psi_\lambda(x)|$ . Para recuperarlas, el PD calcula los coeficientes de on-deletas para cada  $U[\lambda]f$  que son  $\{U[\lambda]f * \psi_{\lambda'}\}_{\lambda'}$ . De nuevo, los coeficientes invariantes a

## 2. Modelización Matemática de una Red Neuronal Convolutiva

traslaciones se obtienen con el módulo  $U[\lambda']U[\lambda]f = |U[\lambda]f * \psi_{\lambda'}|$  y después integrando  $\int_{\mathbb{R}^d} U[\lambda']U[\lambda]f(x)dx$ .

Veamos esto con el mismo ejemplo de antes  $f(x) = \cos(\xi_1 x) + a \cos(\xi_2 x)$  pero con  $a < 1$ . Si  $|\xi_2 - \xi_1| \ll |\lambda|$  con  $|\xi_2 - \xi_1|$  en el soporte de  $\widehat{\psi}_{\lambda'}$ , entonces  $U[\lambda']U[\lambda]f$  es proporcional a  $a \cdot |\psi_{\lambda}(\xi_1)| \cdot |\psi_{\lambda'}(|\xi_2 - \xi_1|)|$ . La segunda ondeleta  $\widehat{\psi}_{\lambda'}$  captura las interferencias creadas por el módulo, entre la frecuencia de las componentes de  $f$  y el soporte de  $\widehat{\psi}_{\lambda}$ .

A continuación introducimos el PD que extiende estas descomposiciones.

**Definición 2.3.** Una secuencia ordenada  $p = (\lambda_1, \lambda_2, \dots, \lambda_m)$  con  $\lambda_k \in \Lambda_{\infty} = 2^{\mathbb{Z}} \times G^+$  se denomina **camino**. Al camino vacío se le denota por  $p = \emptyset$ .

**Definición 2.4.** Un PD es un producto de operadores de la forma  $U[\lambda]f = M[\lambda]W[\lambda]f = |f * \psi_{\lambda}| = |\int_{\mathbb{R}^d} f(u)\psi_{\lambda}(x-u)du|$  para  $f \in L^2(\mathbb{R}^d)$  no conmutativos por un camino ordenado:

$$U[p]f = U[\lambda_m] \dots U[\lambda_2]U[\lambda_1],$$

$$\text{con } U[\emptyset] = Id$$

El operador  $U[p]$  está bien definido en  $L^2(\mathbb{R}^d)$  porque  $\|U[\lambda]f\| = \|f\| \leq \|\psi_{\lambda}\|_1 \|f\|$  para todo  $\lambda \in \Lambda_{\infty}$ .

El PD es por tanto una cascada de convoluciones y módulos:

$$||f * \psi_{\lambda_1}| * \psi_{\lambda_2}| \dots | * \psi_{\lambda_m}|$$

Cada  $U[\lambda]$  filtra la frecuencia del componente en la banda cubierta por  $\widehat{\psi}_{\lambda}$  y lo mapea en un espacio de frecuencias menores con la operación módulo.

### 2.2.3. Propiedades de un camino de frecuencias.

A continuación vamos a probar ciertas propiedades que tienen los caminos de frecuencias tal y como los hemos descrito anteriormente. Para ello empezamos con algunas definiciones que serán de utilidad:

**Definición 2.5.** Escribimos la rotación y reescalo de un camino  $p$  mediante  $2^l g \in 2^{\mathbb{Z}} \times G$  como  $2^l g p = (2^l g \lambda_1, 2^l g \lambda_2, \dots, 2^l g \lambda_m)$ .

**Definición 2.6.** La concatenación de dos caminos  $p$  y  $p'$  se denota por  $p + p' = (\lambda_1, \lambda_2, \dots, \lambda_m, \lambda'_1, \lambda'_2, \dots, \lambda'_{m'})$ . En el caso particular de  $p + \lambda = (\lambda_1, \lambda_2, \dots, \lambda_m, \lambda)$

Con todo lo que sabemos sobre caminos, podemos probar la siguiente propiedad:

**Proposición 2.2.** Sean  $p, p'$  dos caminos, se tiene que :

$$U[p + p'] = U[p']U[p]$$

*Demostración.* Como  $p + p' = (\lambda_1, \lambda_2, \dots, \lambda_m, \lambda'_1, \lambda'_2, \dots, \lambda'_{m'})$  entonces siguiendo la definición de  $U[p]$  se tiene que:

$$U[p + p'] = U[\lambda'_{m'}] \dots U[\lambda'_2]U[\lambda'_1]U[\lambda_m] \dots U[\lambda_2]U[\lambda_1] = U[p']U[p]$$

□

En la **Capítulo 2** veíamos que si  $f$  era compleja, entonces su transformada de ondeletas era  $W_\infty = \{W[\lambda]f\}_{\lambda, -\lambda \in \Lambda_\infty}$ . Pero en este caso, gracias al módulo si  $f$  es compleja, tras la iteración  $U[\lambda_1]f = |W[\lambda_1]f|$  sería una función real, luego para las siguientes transformadas de ondeletas sólo haría falta calcularlas para  $\lambda_k \in \Lambda_\infty$ . Por lo tanto para los propagadores de dispersión de funciones complejas se definen sobre caminos "positivos"  $p = (\lambda_1, \lambda_2, \dots, \lambda_m)$  y caminos "negativos"  $-p = (-\lambda_1, \lambda_2, \dots, \lambda_m)$ .

Sin embargo para simplificar cálculos, todos los resultados siguientes se harán sobre PD aplicados a funciones reales.

#### 2.2.4. Construcción del operador de dispersión.

En este momento ya disponemos de un operador  $U[\lambda]f$  que cumple todas las condiciones deseables, por lo que en esta sección vamos a ser capaces de llegar finalmente a la modelización matemática de una CNN.

**Definición 2.7.** Sea  $\mathcal{P}_\infty$  el conjunto de todos los caminos finitos. La transformada de dispersión de  $f \in L^1(\mathbb{R}^d)$  se define para cualquier camino  $p \in \mathcal{P}_\infty$  como:

$$\bar{S}f(p) = \int_{\mathbb{R}^d} U[p]f(x)dx$$

El operador  $\bar{S}f(p)$  es invariante a traslaciones de  $f$ , pues el operador  $U[p]$  hemos visto que cumple las propiedades necesarias para que el valor de la integral sea finito y por lo tanto sea invariante por traslaciones, y transforma  $f \in L^1(\mathbb{R}^d)$  en una función en el camino de frecuencias variable  $p$ .

Esta definición guarda muchas similitudes con la el módulo de la transformada de Fourier, pero en este caso la transformada es Lipschitz-continua bajo la acción de difeomorfismos, porque se calcula iterando en transformadas de ondeletas y módulos que, como hemos visto anteriormente, son estables.

No obstante, para problemas de clasificación, es mucho más frecuente calcular pequeños descriptores que sean invariantes por traslaciones frente a una escala predefinida  $2^J$ , manteniendo las frecuencias superiores a  $2^J$ , lo que nos permite ver esta variabilidad espacial. Esto se consigue convolucionando la transformada con una ventana escalada a la frecuencia deseada, en nuestro caso  $\phi_{2^J}(x) = 2^{-dJ}\phi(2^{-J}x)$ .

**Definición 2.8.** Sea  $J \in \mathbb{Z}$  y  $\mathcal{P}_J$  el conjunto de caminos finitos  $p = (\lambda_1, \lambda_2, \dots, \lambda_m)$  con  $\lambda_k \in \Lambda_J$  y  $|\lambda_k| = 2^{jk} > 2^{-J}$ . Una ventana de transformada de dispersión se define para todo  $p \in \mathcal{P}_J$  por

$$S_J[p]f(x) = U[p]f * \phi_{2^J}(x) = \int_{\mathbb{R}^d} U[p]f(u)\phi_{2^J}(x-u)du.$$

Dónde la convolución con  $\phi_{2^J}$  localiza el propagador de dsipersión en dominios proporcionales a  $2^J$ .

$$S_J[p]f(x) = ||f * \psi_{\lambda_1}| * \psi_{\lambda_2}| \dots | * \psi_{\lambda_m}| * \phi_{2^J}(x).$$

Con  $S_J[\emptyset]f = f * \phi_{2^J}$ .

Esto define una familia infinita de funciones indexadas por  $\mathcal{P}_J$ , denotada por

$$S_J[\mathcal{P}_J]f := \{S_J[p]f\}_{p \in \mathcal{P}_J}.$$

Si nos fijamos, para cada camino  $p$ ,  $S_J[p]f(x)$  es una función que actúa sobre la ventana centrada en la posición  $x$  cuyo tamaño serían intervalos de dimensión  $2^J$ .

Para el caso de funciones complejas solo tendríamos que incluir en  $\mathcal{P}_J$  los caminos negativos, y si  $f$  es real  $S_J[-p] = S_J[p]f$ . En la [Sección 2.3](#) se comprueba que para ondeletas apropiadas,  $\|f\|^2 = \sum_{p \in \mathcal{P}_J} \|S_J[p]f\|^2$ .

Sin embargo, la energía de señal se concentra en un conjunto mucho más pequeño de caminos de frecuencias descendentes  $p = (\lambda_k)_{k \leq m}$  en el cual  $|\lambda_{k+1}| \leq |\lambda_k|$ . Esto ocurre porque como mencionamos antes, el propagador  $U[\lambda]$  progresivamente lleva la energía de la señal a frecuencias cada vez menores, hasta que en cierto punto es nula.

Veamos ahora la relación que guarda este propagador de ventana con el que se definió originalmente en [Def. 2.7](#). Como  $\phi(x)$  es continua en 0, si  $f \in L^1(\mathbb{R}^d)$  se tiene que su transformada de dispersión de ventana converge punto a punto a la transformada de dispersión cuando la escala  $2^J$  tiende a  $\infty$ :

$$\begin{aligned} \forall x \in \mathbb{R}^d \quad \lim_{J \rightarrow \infty} 2^{dJ} S_J[p]f(x) &= \lim_{J \rightarrow \infty} 2^{dJ} U[p]f * \phi_{2^J}(x) \\ &= \lim_{J \rightarrow \infty} 2^{dJ} \int_{\mathbb{R}^d} U[p]f(u) \phi_{2^J}(x - u) du \\ &= \lim_{J \rightarrow \infty} 2^{dJ} \int_{\mathbb{R}^d} U[p]f(u) 2^{-dJ} \phi(2^{-J}(x - u)) du \\ &= \int_{\mathbb{R}^d} U[p]f \phi(0) du \\ &= \phi(0) \int_{\mathbb{R}^d} U[p]f(u) du \\ &= \phi(0) \overline{Sf}(p). \end{aligned}$$

## 2.3. Propagador de dispersión y conservación de la Norma

### 2.3.1. Proceso de dispersión del propagador.

Hasta ahora hemos probado que el propagador  $S_J$  es no-expansivo y que preserva la norma de  $L^2(\mathbb{R}^d)$ . A partir de ahora denotamos por  $S_J[\Omega] := \{S_J[p]\}_{p \in \Omega}$  y  $U[\Omega] := \{U[p]\}_{p \in \Omega}$  a la familia de operadores indexados por el conjunto de caminos  $\Omega \subset \mathcal{P}_\infty$ .

Un dispersor de ventanas  $S_J$  puede calcularse iterando en el propagador de un paso definido anteriormente como:

$$U_J f = \{A_J f, (U[\lambda]f)_{\lambda \in \Lambda_J}\},$$

con  $A_J = f * \phi_{2^J}$  y  $U[\lambda]f = |f * \psi_\lambda|$ .



Tras calcular  $U_J f$ , aplicando de nuevo  $U_J$  a cada coeficiente  $U[\lambda]f$  se genera una familia infinita aún más grande de funciones. La descomposición se continúa iterando por recursividad aplicando  $U_J$  a cada  $U[p]f$ .

Teniendo en cuenta **Proposición 2.2** se tiene que  $U[\lambda]U[p] = U[p + \lambda]$ , y  $A_J U[p] = S_J[p]$ , esto dando lugar a :

$$U_J U[p] = \{S_J[p]f, (U[p + \lambda]f)_{\lambda \in \Lambda_J}\}.$$

Podemos por tanto establecer el comportamiento de la transformada de dispersión según la longitud  $m$  del camino que estamos empleando. Sea  $\Lambda_J^m$  el conjunto de caminos de longitud  $m$  con  $\Lambda_J^0 = \emptyset$ , entonces:

$$U_J U[\Lambda_J^m] = \{S_J[\Lambda_J^m]f, (U[\Lambda_J^{m+1}]f)_{\lambda \in \Lambda_J}\}. \quad (2.7)$$

Del hecho de que  $\mathcal{P}_J = \cup_{m \in \mathbb{N}} \Lambda_J^m$ , uno puede calcular  $S_J[\mathcal{P}_J]f$  a partir de  $f = U[\emptyset]f$  iterativamente calculando  $U_J U[\Lambda_J^m]f$  para  $m$  tendiendo a  $\infty$ , tal y cómo se puede ver en la imagen **Figura 2.4.**




Figura 2.4.: Un PD  $U_J$  aplicado a un punto de una señal  $f(x)$  calcula  $U[\lambda_1]f(x) = |f(x) * \psi_{\lambda_1}|$  y como salida a la capa  $m = 0$  se promedian los coeficientes que han dado 0 (por tener  $2^j < 2^{-j}$ ) obteniendo como salida  $S_J[\emptyset]f(x) = f(x) * \phi_{2^j}$  (como se puede ver en la flecha negra). Después se aplica de nuevo  $U_J$  a cada coeficiente  $U[\lambda_1]f(x)$  del paso anterior ( $m = 1$ )  $U[\lambda_1, \lambda_2]f(x)$  obteniendo como salida  $S_J[\lambda_1]f(x) = U[\lambda_1]f(x) * \phi_{2^j}$ . Se repite este proceso de manera recursiva para cada coeficiente  $U[p]f(x)$  y obteniendo como resultado  $S_J[p]f(x) = U[p]f(x) * \phi_{2^j}$ .

### 2.3.2. Diferencias y similitudes con una CNN

Las operaciones de la transformada de dispersión que hemos descrito siguen la estructura general de la red neuronal convolucional introducida por LeCun [LBH15], pues se describen las redes convolucionales como una cascada de convoluciones (la transformada de ondeletas  $W[\lambda]$ ) y capas de "pooling" que usan funciones no lineales (el operador módulo  $M[\lambda]$ ), las cuales se representan en este modelo como módulos de números complejos. También se

puede considerar como un operador de “pooling” la función  $\phi_{2^j}$  que se emplea para agregar coeficientes y contruir un operador invariante.

Las redes neuronales convolucionales han sido empleadas con mucho éxito en tareas de reconocimiento de objetos o personas y usan normalmente Kernels que no son predefinidos, sino que se aprenden mediante la técnica de back-propagation al entrenar la red, en cambio, en la modelización que se ha presentado las ondeletas que usamos son prefijadas y no se aprenden.

Siguiendo con las similitudes entre ambos modelos, si  $p$  es un camino de longitud  $m$ , entonces a  $S_J[p]f(x)$  se le denomina coeficiente de orden  $m$  a escala  $2^j$ , que en el caso de una CNN, equivaldría al tensor formado por los mapas de activación tras la convolución con el kernel de la capa  $m$  de la red.

### 2.3.3. Relación con herramientas clásicas de visión por computador

Por otro lado, la modelización con los algoritmos clásicos de visión por computador como SIFT [Low04] para calcular puntos de interés en imágenes. Así, con la ondeletas apropiadas, los coeficientes de primer orden  $S[\lambda_1]f$  serían equivalentes a los coeficientes del algoritmo. De hecho, en el artículo sobre el descriptor DAISY [TLF10] se muestra cómo esos coeficientes son aproximados por  $S_J[2^j r]f = |f * \psi_{2^j r}| * \phi_{2^j}(x)$ , donde  $\psi_{2^j r}$  es la derivada parcial de una Gaussiana calculada en imagen de escala  $2^j$  de mayor calidad, para 8 rotaciones distintas  $r$ . El filtro para promediar  $\phi_{2^j}$  es un filtro Gaussiano escalado.

### 2.3.4. Operador no expansivo.

El propagador  $U_J f = \{A_J f, (|W[\lambda]f|)_{\lambda \in \Lambda_J}\}$  es no expansivo, porque la transformada de ondas  $W_J$  es unitaria pues cumple las hipótesis de la **Proposición 2.1** y el módulo no es expansivo en el sentido de que  $||a| - |b|| \leq |a - b|$  para cualquier  $(a, b) \in \mathbb{C}^2$ . Esto es válido tanto si  $f$  es real o compleja. Como consecuencia:

$$\begin{aligned} ||U_J f - U_J h||^2 &= ||A_J f - A_J h||^2 + \sum_{\lambda \in \Lambda_J} |||W[\lambda]f| - |W[\lambda]h|||^2 \\ &\leq ||W_J f - W_J h||^2 \leq ||f - h||^2 \end{aligned}$$

Al ser  $W_J$  unitaria, tomando la función nula  $h = 0$  y siguiendo el mismo razonamiento anterior, también se comprueba que  $||U_J f|| = ||f||$  por lo que el operador  $U_J$  preserva la norma.

Para todo conjunto de caminos  $\Omega$ , las normas de  $S_J[\Omega]f$  y  $U[\Omega]f$  son:

$$||S_J[\Omega]f||^2 = \sum_{p \in \Omega} ||S_J[p]f||^2 \quad y \quad ||U[\Omega]f||^2 = \sum_{p \in \Omega} ||U[p]f||^2$$

Como  $S_J[\mathcal{P}_J]$  itera en  $U_J$ , que es no expansivo, la siguiente proposición prueba que  $S_J[\Omega]f$  es también no expansivo.

**Proposición 2.3.** *La transformada de dispersión de ventana es no expansiva:*

$$\forall (f, h) \in L^2(\mathbb{R}^d)^2 \quad ||S_J[\mathcal{P}_J]f - S_J[\mathcal{P}_J]h|| \leq ||f - h||$$

*Demostración.* Como  $U_J$  es no expansiva, partiendo de (2.7) que nos dice:

$$U_J U[\Lambda_J^m] = \{S_J[\Lambda_J^m]f, (U[\Lambda_J^{m+1}]f)_{\lambda \in \Lambda_J}\},$$

se tiene que:

$$\begin{aligned} \|U[\Lambda_J^m]f - U[\Lambda_J^m]h\|^2 &\geq \|U_J U[\Lambda_J^m]f - U_J U[\Lambda_J^m]h\|^2 \\ &= \|S_J[\Lambda_J^m]f - S_J[\Lambda_J^m]h\|^2 + \|U[\Lambda_J^{m+1}]f - U[\Lambda_J^{m+1}]h\|^2. \end{aligned}$$

Si ahora sumamos en  $m$  cuando tiende a  $\infty$  se obtiene que:

$$\sum_{m=0}^{\infty} \|U[\Lambda_J^m]f - U[\Lambda_J^m]h\|^2 \geq \sum_{m=0}^{\infty} \|S_J[\Lambda_J^m]f - S_J[\Lambda_J^m]h\|^2 + \sum_{m=0}^{\infty} \|U[\Lambda_J^{m+1}]f - U[\Lambda_J^{m+1}]h\|^2,$$

que equivale a:

$$\sum_{m=0}^{\infty} \|U[\Lambda_J^m]f - U[\Lambda_J^m]h\|^2 - \sum_{m=0}^{\infty} \|U[\Lambda_J^{m+1}]f - U[\Lambda_J^{m+1}]h\|^2 \geq \sum_{m=0}^{\infty} \|S_J[\Lambda_J^m]f - S_J[\Lambda_J^m]h\|^2$$

Si ahora nos fijamos en el lado izquierdo de la desigualdad, se cancelan todos los términos salvo  $m = 0$ , y teniendo en cuenta que  $\Lambda_J^0 = \emptyset$  queda:

$$\sum_{m=0}^{\infty} \|U[\Lambda_J^0]f - U[\Lambda_J^0]h\|^2 = \sum_{m=0}^{\infty} \|U[\emptyset]f - U[\emptyset]h\|^2 = \|f - h\|^2$$

Por otro lado, se tiene que

$$\sum_{m=0}^{\infty} \|S_J[\Lambda_J^m]f - S_J[\Lambda_J^m]h\|^2 = \|S_J[\mathcal{P}_J]f - S_J[\mathcal{P}_J]h\|^2.$$

Luego hemos probado que

$$\|S_J[\mathcal{P}_J]f - S_J[\mathcal{P}_J]h\|^2 \leq \|f - h\|^2$$

y por lo tanto que la transformada de dispersión de ventana es no expansiva.  $\square$

### 2.3.5. Conservación de la norma.

En la **Capítulo 2** se obtuvo que cada coeficiente  $U[\lambda]f = |f * \psi_\lambda|$  capturaba la energía de frecuencia de  $f$  en una banda de frecuencia cubierta por  $\widehat{\psi}_\lambda$  y propagaba dicha energía a frecuencias decrecientes, este hecho lo demuestra el siguiente teorema, mostrando que toda la energía del propagador de dispersión alcanza la frecuencia mínima  $2^J$  y es atrapada por el filtro paso bajo  $\phi_{2^J}$ . La energía propagada tiende a 0 conforme se incrementa la longitud del camino, y el teorema implica que  $\|S_J[\mathcal{P}_J]f\| = \|f\|$ . Esto se aplica también a funciones complejas en caminos negativos.

Para la demostración de la conservación de la norma necesitamos unos resultados previos:

**Lema 2.4.** Si  $h$  es una funciones tal que  $h \geq 0$  entonces  $\forall f \in L^2(\mathbb{R}^d)$ :

$$|f * \psi_\lambda| * h \geq \sup_{\eta \in \mathbb{R}^d} |f * \psi_\lambda * h_\eta| \text{ con } h_\eta = h(x)e^{i\eta x}$$

*Demostración.*

$$\begin{aligned} |f * \psi_\lambda| * h(x) &= \int \left| \int f(v) \psi_\lambda(u-v) dv \right| h(x-u) du \\ &= \int \left| \int f(v) \psi_\lambda(u-v) e^{i\eta(x-u)} h(x-u) dv \right| du \\ &\geq \left| \int \int f(v) \psi_\lambda(u-v) e^{i\eta(x-u)} h(x-u) dv du \right| = \\ &= \left| \int f(v) \int \psi_\lambda(x-v-u') h(u') e^{i\eta u'} du' dv \right| \\ &= \left| \int f(v) \psi_\lambda * h_\eta(x-v) dv \right| = |f * \psi_\lambda * h_\eta| \end{aligned}$$

Dónde se ha usado el cambio de variable  $u' = x - u$  con  $J = 1$ . □

A continuación definimos el concepto de “ondeleta admisible:”

**Definición 2.9.** Una ondeleta de dispersión se dice que es admisible si existe  $\eta \in \mathbb{R}^d$  y una función  $\rho \geq 0$ , con  $|\widehat{\rho}(\omega)| \leq |\widehat{\phi}(2\omega)|$  y  $\widehat{\rho}(0) = 1$ , tal que la función:

$$\widehat{\Psi}(\omega) = |\widehat{\rho}(\omega - \eta)|^2 - \sum_{k=1}^{+\infty} k(1 - |\widehat{\rho}(2^{-k}(\omega - \eta))|^2) \quad (2.8)$$

satisface:

$$\alpha = \inf_{1 \leq |w| \leq 2} \sum_{j=-\infty}^{\infty} \sum_{r \in G} \widehat{\Psi}(2^{-j}r^{-1}\omega) |\widehat{\psi}(2^{-j}r^{-1}\omega)|^2 > 0. \quad (2.9)$$

Con esta definición en mente podemos comprobar que se da el siguiente lema que demuestra que el propagador dispersa la energía progresivamente hacia bajas frecuencias.

**Lema 2.5.** Si (2.9) se satisface y

$$\|f\|_w^2 = \sum_{j=0}^{\infty} \sum_{r \in G^+} j \|W[2^j r]f\|^2 < \infty$$

Entonces se tiene:

$$\frac{\alpha}{2} ||U[\mathcal{P}_J]f||^2 \geq \max(J+1, 1) ||f||^2 + ||f||_w^2. \quad (2.10)$$

La demostración de lema se encuentra en el apéndice A de [Mal12].

Con todos estos resultados podemos presentar el principal teorema de esta sección, que nos dará como resultado la preservación de la norma del operador de ventana:

**Teorema 2.2.** *Si las ondeletas son admisibles, entonces para toda  $f \in L^2(\mathbb{R}^d)$*

$$\lim_{m \rightarrow \infty} ||U[\Lambda_f^m]f||^2 = \lim_{m \rightarrow \infty} \sum_{n=m}^{\infty} ||S_J[\Lambda_f^n]f||^2 = 0$$

y

$$||S_J[\mathcal{P}_J]f|| = ||f||$$

*Demostración.* Esta demostración tiene dos partes, la primera consistirá en demostrar que la condición (2.8) implica que  $\lim_{m \rightarrow \infty} ||U[\Lambda_f^m]f||^2 = 0$ .

La clave de esto reside en el Lema 2.4, que nos da una cota inferior de  $|f * \psi_\lambda|$  convolucionada con una función positiva. La clase de funciones para las que  $||f||_w < \infty$  es una clase logarítmica de Sobolev correspondiente a funciones que tienen un módulo promedio continuo en  $L^2(\mathbb{R}^d)$ . Como

$$||U[\mathcal{P}_J]f||^2 = \sum_{m=0}^{+\infty} ||U[\Lambda_f^m]f||^2,$$

si  $||f||_w < \infty$  entonces (2.10) implica que  $\lim_{m \rightarrow \infty} ||U[\Lambda_f^m]f|| = 0$ . Este resultado se extiende en  $L^2(\mathbb{R}^d)$  por densidad. Como  $\phi \in L^1(\mathbb{R}^d)$  y  $\hat{\phi}(0) = 1$ , cualquier  $f \in L^2(\mathbb{R}^d)$  satisface  $\lim_{n \rightarrow -\infty} ||f - f_n|| = 0$ , donde  $f_n = f * \phi_{2^n}$  y  $\phi_{2^n} = 2^{-nd}\phi(2^{-n}x)$ . Se demuestra por tanto que  $\lim_{m \rightarrow \infty} ||U[\Lambda_f^m]f_n|| = 0$  viendo que  $||f_n||_w < \infty$ . De hecho,

$$\begin{aligned} ||W[2^j r]f_n||^2 &= \int |\hat{f}(\omega)|^2 |\hat{\phi}(2^n \omega)|^2 |\hat{\psi}(2^{-j} r^{-1} \omega)|^2 d\omega \\ &\leq C 2^{-2n-2j} \int |\hat{f}(\omega)|^2 d\omega, \end{aligned}$$

porque  $\psi$  hay un momento en que desaparece entonce  $|\hat{\psi}(\omega)| = O(|\omega|)$ , y las derivadas de  $\phi$  están en  $L^1(\mathbb{R}^d)$  luego  $|\omega| |\hat{\phi}(\omega)|$  están acotadas. Por lo que se tiene que  $||f_n||_w < \infty$ .

Como  $U[\Lambda^m]$  es no expansiva,  $||U[\Lambda_f^m]f - U[\Lambda_f^m]f_n|| \leq ||f - f_n||$ , por lo que

$$||U[\Lambda_f^m]f|| \leq ||f - f_n|| + ||U[\Lambda_f^m]f_n||.$$

Como  $\lim_{n \rightarrow -\infty} ||f - f_n|| = 0$  y  $\lim_{m \rightarrow \infty} ||U[\Lambda_f^m]f_n|| = 0$  tenemos que

$$\lim_{m \rightarrow \infty} ||U[\Lambda_f^m]f||^2 = 0$$

para toda  $f \in L^2(\mathbb{R}^d)$ .

## 2. Modelización Matemática de una Red Neuronal Convolutiva

En **segundo lugar** vamos a ver que las siguientes expresiones son equivalentes:

$$\lim_{m \rightarrow \infty} \|U[\Lambda_J^m]f\|^2 = 0 \iff \lim_{m \rightarrow \infty} \sum_{n=m}^{\infty} \|S_J[\Lambda_J^n]f\|^2 = 0 \iff \|S_J[\mathcal{P}_J]f\|^2 = \|f\|^2$$

En primer lugar probamos que

$$\lim_{m \rightarrow \infty} \|U[\Lambda_J^m]f\|^2 = 0 \iff \lim_{m \rightarrow \infty} \sum_{n=m}^{\infty} \|S_J[\Lambda_J^n]f\|^2 = 0$$

Como  $\|U_J h\| = \|h\| \forall h \in L^2(\mathbb{R}^d)$  y  $U_J U[\Lambda_J^n]f = \{S_J[\Lambda_J^n]f, U[\Lambda_J^{n+1}]f\}$ ,

$$\|U[\Lambda_J^n]f\|^2 = \|U_J U[\Lambda_J^n]f\|^2 = \|S_J[\Lambda_J^n]f\|^2 + \|U[\Lambda_J^{n+1}]f\|^2. \quad (2.11)$$

Sumando en  $m \leq n < \infty$  se obtiene :

$$\begin{aligned} \sum_{n=m}^{\infty} \|U[\Lambda_J^n]f\|^2 &= \sum_{n=m}^{\infty} \|S_J[\Lambda_J^n]f\|^2 + \sum_{n=m}^{\infty} \|U[\Lambda_J^{n+1}]f\|^2 \\ &\iff \\ \sum_{n=m}^{\infty} \|U[\Lambda_J^n]f\|^2 - \sum_{n=m}^{\infty} \|U[\Lambda_J^{n+1}]f\|^2 &= \sum_{n=m}^{\infty} \|S_J[\Lambda_J^n]f\|^2 \end{aligned}$$

En el término de la izquierda se anulan entre si todos los sumandos salvo  $n = m$ , luego queda:

$$\|U[\Lambda_J^m]f\|^2 = \sum_{n=m}^{\infty} \|S_J[\Lambda_J^n]f\|^2$$

Y tomando límites cuando  $m \rightarrow \infty$

$$\lim_{m \rightarrow \infty} \|U[\Lambda_J^m]f\|^2 = \lim_{m \rightarrow \infty} \sum_{n=m}^{\infty} \|S_J[\Lambda_J^n]f\|^2$$

Llegados a este punto se puede apreciar claramente que

$$\text{Si } \lim_{m \rightarrow \infty} \|U[\Lambda_J^m]f\|^2 = 0 \implies \lim_{m \rightarrow \infty} \sum_{n=m}^{\infty} \|S_J[\Lambda_J^n]f\|^2 = 0$$

Y el recíproco también es cierto, luego ambas expresiones son equivalentes.

Por otro lado, sumando en (2.11) para  $0 \leq n < m$  se obtiene:

$$\begin{aligned} \sum_{n=0}^{m-1} \|U[\Lambda_j^n]f\|^2 &= \sum_{n=0}^{m-1} \|S_J[\Lambda_j^n]f\|^2 + \sum_{n=0}^{m-1} \|U[\Lambda_j^{n+1}]f\|^2 \\ &\Updownarrow \\ \sum_{n=0}^{m-1} \|U[\Lambda_j^n]f\|^2 - \sum_{n=0}^{m-1} \|U[\Lambda_j^{n+1}]f\|^2 &= \sum_{n=0}^{m-1} \|S_J[\Lambda_j^n]f\|^2. \end{aligned}$$

En el término de la izquierda se anulan entre si todos los sumandos salvo  $n = 0$ , y teniendo en cuenta que  $f = U[\Lambda_j^0]f$  queda:

$$\|f\|^2 = \sum_{n=0}^{m-1} \|S_J[\Lambda_j^n]f\|^2 + \|U[\Lambda_j^m]f\|^2.$$

Si ahora tomamos límite cuando  $m \rightarrow \infty$  obtenemos:

$$\begin{aligned} \lim_{m \rightarrow \infty} \|f\|^2 &= \lim_{m \rightarrow \infty} \sum_{n=0}^{m-1} \|S_J[\Lambda_j^n]f\|^2 + \lim_{m \rightarrow \infty} \|U[\Lambda_j^m]f\|^2 \\ &\Updownarrow \\ \|f\|^2 &= \sum_{n=0}^{\infty} \|S_J[\Lambda_j^n]f\|^2 + \lim_{m \rightarrow \infty} \|U[\Lambda_j^m]f\|^2 \\ &\Updownarrow \\ \|f\|^2 &= \|S_J[\mathcal{P}_{\mathcal{J}}]f\|^2 + \lim_{m \rightarrow \infty} \|U[\Lambda_j^m]f\|^2. \end{aligned}$$

De manera que se puede apreciar claramente que

$$\|f\|^2 = \|S_J[\mathcal{P}_{\mathcal{J}}]f\|^2 + \lim_{m \rightarrow \infty} \|U[\Lambda_j^m]f\|^2 = \|S_J[\mathcal{P}_{\mathcal{J}}]f\|^2 \iff \lim_{m \rightarrow \infty} \|U[\Lambda_j^m]f\|^2 = 0.$$

Con lo que queda demostrado el teorema □

### 2.3.6. Conclusiones extraídas del teorema

La demostración muestra que el propagador dispersa la energía progresivamente a frecuencias menores. La energía de  $U[p]f$  se concentra principalmente en los caminos de frecuencia decrecientes  $p = (\lambda_k)_{k \leq m}$  para los que  $|\lambda_{k+1}| < |\lambda_k|$ .

El decrecimiento de  $\sum_{n=m}^{\infty} \|S_J[\Lambda_j^n]f\|^2$  nos sugiere que podemos descartar todos los caminos de longitud mayor que un cierto  $m > 0$ . De hecho, en tareas de tratamiento de imágenes y audio el decrecimiento numérico de  $\|S_J[\Lambda_j^n]f\|^2$  puede llegar a ser exponencial, lo que conlleva a que en problemas de clasificación, por ejemplo, el de camino se limite a  $m = 3$ .

## 2. Modelización Matemática de una Red Neuronal Convolutiva

El teorema además requiere de una transformada de ondeleta unitaria y admisible que satisfaga la condición de Littlewood-Paley  $\beta \sum_{(j,r) \in \mathbb{Z} \times G} |\hat{\psi}(2^j r \omega)|^2 = 1$ .

Debe también existir una función  $\rho \geq 0$  y un  $\eta \in \mathbb{R}^d$  con  $|\hat{\rho}(\omega)| \leq |\hat{\phi}(2\omega)|$  tal que:

$$\sum_{(j,r) \in \mathbb{Z} \times G} |\hat{\psi}(2^j r \omega)|^2 |\hat{\rho}(2^j r \omega - \eta)|^2$$

sea suficientemente grande para que  $\alpha > 0$ . Esto se puede obtener como se indica en (2.3), con  $\psi(x) = e^{i\eta x} \Theta(x)$  y de hecho  $\hat{\psi} = \hat{\Theta}(\omega - \eta)$ , dónde  $\hat{\Theta}$  y  $\hat{\rho}$  tienen su energía concentrada en los mismos dominios de frecuencia, que son bajos.



### 3. Invarianza por Traslaciones

Hasta ahora hemos definido el propagador de dispersión y hemos visto algunas propiedades como la conservación de la norma de la señal  $f$ . No obstante, aún quedan por demostrar propiedades que son esenciales como son la invarianza por traslaciones o la estabilidad bajo la acción de difeomorfismos. En esta sección nos centraremos en el estudio de la invarianza por traslaciones.

#### 3.1. No expansividad del operador de ventana en conjuntos de caminos

Vamos a demostrar en primer lugar que  $\|S_J[\mathcal{P}_J]f - S_J[\mathcal{P}_J]h\|$  es no expansiva cuando se incrementa  $J$ , y que de hecho converge cuando  $J \rightarrow \infty$ . Esto define una distancia límite que como veremos a continuación es invariante por traslaciones.

**Proposición 3.1.** Para todo  $(f, h) \in L^2(\mathbb{R}^d)^2$  y  $J \in \mathbb{Z}$ ,

$$\|S_{J+1}[\mathcal{P}_{J+1}]f - S_{J+1}[\mathcal{P}_{J+1}]h\| \leq \|S_J[\mathcal{P}_J]f - S_J[\mathcal{P}_J]h\| \quad (3.1)$$

*Demostración.* En primer lugar, vamos a transformar la condición que queremos demostrar en (3.1) en otra equivalente y que será más fácil de probar.

Si recordamos la definición de  $\mathcal{P}_J$ , era un conjunto de caminos finitos  $p = (\lambda_1, \dots, \lambda_m)$  tal que  $\lambda_k \in \Lambda_J$  y  $|\lambda_k| = 2^{jk} > 2^{-J}$ . Luego todo camino  $p' \in \mathcal{P}_{J+1}$ , puede ser unívocamente escrito como una extensión de un camino  $p \in \mathcal{P}_J$  donde  $p$  es el prefijo más grande de  $p'$  que pertenece a  $\mathcal{P}_J$ , y  $p' = p + q$  para algún  $q \in \mathcal{P}_{J+1}$ . De hecho, podemos definir el conjunto de todas las extensiones de  $p \in \mathcal{P}_J$  en  $\mathcal{P}_{J+1}$  como:

$$\mathcal{P}_{J+1}^p = p \cup p + 2^{-J}r + p'' \quad r \in G^+, p'' \in \mathcal{P}_{J+1}$$

Esto define una partición disjunta de  $\mathcal{P}_{J+1} = \cup_{p \in \mathcal{P}_J} \mathcal{P}_{J+1}^p$ . Y deberíamos probar que dichas extensiones son no expansivas,

$$\sum_{p' \in \mathcal{P}_{J+1}^p} \|S_{J+1}[p']f - S_{J+1}[p']h\|^2 \leq \|S_J[p]f - S_J[p]h\|^2. \quad (3.2)$$

Finalmente, si nos fijamos, la condición (3.2) equivale a (3.1) sumando en todo  $p \in \mathcal{P}_J$ , luego probando (3.2) tendríamos el resultado que buscamos.

Para ello vamos a necesitar el siguiente lema:

**Lema 3.1.** Para Ondeletras que satisfacen la propiedad **Proposición 2.1**, para toda función real  $f \in L^2(\mathbb{R}^d)$  y todo  $q \in \mathbb{Z}$  se verifica:

$$\sum_{-q \geq l > -J} \sum_{r \in G^+} \|f * \psi_{2^l r}\|^2 + \|f * \phi_{2^J}\|^2 = \|f * \phi_{2^q}\|^2$$

### 3. Invarianza por Traslaciones

*Demostración.* En primer lugar vamos a ver que de **Proposición 2.1** se deduce la siguiente expresión:

$$|\widehat{\phi}(2^J \omega)|^2 + \sum_{-q \geq l > -J} \sum_{r \in G^+} |\widehat{\psi}(2^{-l} r^{-1} \omega)|^2 = |\widehat{\phi}(2^q \omega)|^2$$

Para ello, de la expresión

$$\frac{1}{2} \sum_{j=-\infty}^{\infty} \sum_{r \in G} |\widehat{\psi}(2^{-j} r^{-1} \omega)|^2 = 1 \quad y \quad |\widehat{\phi}(\omega)|^2 = \frac{1}{2} \sum_{j=-\infty}^0 \sum_{r \in G} |\widehat{\psi}(2^{-j} r^{-1} \omega)|^2,$$

se tiene de la misma forma que vimos en la demostración del teorema que:

$$\forall J \in \mathbb{Z} \quad \left| \widehat{\phi}(2^J \omega) \right|^2 + \frac{1}{2} \sum_{j > -J, r \in G} \left| \widehat{\psi}(2^{-j} r^{-1} \omega) \right|^2 = 1.$$

Y partiendo el sumatorio obtenemos que:

$$\left| \widehat{\phi}(2^J \omega) \right|^2 + \frac{1}{2} \sum_{-q \geq j > -J, r \in G} \left| \widehat{\psi}(2^{-j} r^{-1} \omega) \right|^2 = \frac{1}{2} \sum_{j > -q, r \in G} \left| \widehat{\psi}(2^{-j} r^{-1} \omega) \right|^2 = |\widehat{\phi}(2^q \omega)|^2$$

Ahora multiplicamos en la expresión anterior por  $|\widehat{f}(\omega)|^2$ ,

$$\left| \widehat{f}(\omega) \right|^2 \left| \widehat{\phi}(2^J \omega) \right|^2 + \frac{1}{2} \sum_{-q \geq j > -J, r \in G} \left| \widehat{f}(\omega) \right|^2 \left| \widehat{\psi}(2^{-j} r^{-1} \omega) \right|^2 = \left| \widehat{f}(\omega) \right|^2 |\widehat{\phi}(2^q \omega)|^2.$$

Integramos en  $\omega$ ,

$$\int \left| \widehat{f}(\omega) \right|^2 \left| \widehat{\phi}(2^J \omega) \right|^2 d\omega + \frac{1}{2} \sum_{-q \geq j > -J, r \in G} \int \left| \widehat{f}(\omega) \right|^2 \left| \widehat{\psi}(2^{-j} r^{-1} \omega) \right|^2 d\omega = \int \left| \widehat{f}(\omega) \right|^2 |\widehat{\phi}(2^q \omega)|^2 d\omega.$$

Ahora estamos en condiciones de aplicar el **Teorema 2.1**, y nos quedaría que la expresión anterior equivale a:

$$\int |(f * \phi_{2^J})(x)|^2 dx + \sum_{-q \geq j > -J, r \in G} \int |(f * \psi_{2^j r})(x)|^2 dx = \int |(f * \phi_{2^q})(x)|^2 dx,$$

Y teniendo en cuenta que  $f$  es real y por lo tanto que  $\|f * \psi_{2^j r}\| = \|f * \psi_{2^j -r}\|$  junto con la definición de la norma de  $L^2(\mathbb{R}^d)$ , se tiene

$$\sum_{-q \geq l > -J} \sum_{r \in G^+} \|f * \psi_{2^l r}\|^2 + \|f * \phi_{2^J}\|^2 = \|f * \phi_{2^q}\|^2$$

□

### 3.1. No expansividad del operador de ventana en conjuntos de caminos

Vamos ahora a usar el lema anterior con la función  $g = U[p]f - U[p]h$  junto con que  $U[p]f * \phi_{2^J} = S_J[p]f$ . De esta forma se tiene:

$$\|g * \phi_{2^{J+1}}\|^2 + \sum_{r \in G^+} \|g * \psi_{2^{-J}r}\|^2 = \|g * \phi_{2^J}\|^2.$$

Así, sustituyendo el valor de  $g$  por el que hemos definido antes y aplicando la propiedad distributiva de la convolución:

$$\begin{aligned} \|U[p]f * \phi_{2^J} - U[p]h * \phi_{2^J}\|^2 &= \|U[p]f * \phi_{2^{J+1}} - U[p]h * \phi_{2^{J+1}}\|^2 \\ &\quad + \sum_{r \in G^+} \|U[p]f * \psi_{2^{-J}r} - U[p]h * \psi_{2^{-J}r}\|^2. \end{aligned}$$

Y esto equivale a

$$\begin{aligned} \|S_J[p]f - S_J[p]h\|^2 &= \|S_{J+1}[p]f - S_{J+1}[p]h\|^2 \\ &\quad + \sum_{r \in G^+} \|U[p]f * \psi_{2^{-J}r} - U[p]h * \psi_{2^{-J}r}\|^2. \end{aligned}$$

Aplicando ahora la propiedad de la norma de que  $\|a - b\| \geq ||a| - |b||$ . Y como

$$|U[p]f * \psi_{2^{-J}r}| = |U[p + 2^{-J}r]f|$$

se concluye que:

$$\begin{aligned} \|S_J[p]f - S_J[p]h\|^2 &\geq \|S_{J+1}[p]f - S_{J+1}[p]h\|^2 \\ &\quad + \sum_{r \in G^+} \|U[p + 2^{-J}r]f - U[p + 2^{-J}r]h\|^2. \end{aligned}$$

Como  $S_{J+1}[\mathcal{P}_{J+1}]U[p + 2^{-J}r]f = \{S_{J+1}[p + 2^{-J}r + p'']\}_{p'' \in \mathcal{P}_{J+1}}$  y  $S_{J+1}[\mathcal{P}_{J+1}]f$  es no expansiva por **Proposición 2.3**, esto implica que

$$\begin{aligned} \|S_J[p]f - S_J[p]h\|^2 &\geq \|S_{J+1}[p]f - S_{J+1}[p]h\|^2 \\ &\quad + \sum_{p'' \in \mathcal{P}_{J+1}} \sum_{r \in G^+} \|S_{J+1}[p + 2^{-J}r + p'']f - S_{J+1}[p + 2^{-J}r + p'']h\|^2, \end{aligned}$$

y en particular

$$\|S_J[p]f - S_J[p]h\|^2 \geq \sum_{p'' \in \mathcal{P}_{J+1}} \sum_{r \in G^+} \|S_{J+1}[p + 2^{-J}r + p'']f - S_{J+1}[p + 2^{-J}r + p'']h\|^2,$$

que demuestra (3.2). □

### 3.2. Invarianza por traslaciones

Esta proposición anterior nos demuestra que  $\|S_J[\mathcal{P}_J] - S_J[\mathcal{P}_J]h\|$  es positivo y no creciente cuando  $J$  se incrementa, y de hecho converge. Como  $S_J[\mathcal{P}_J]$  es no expansiva, el límite tampoco:

$$\forall (f, h) \in L^2(\mathbb{R}^d)^2 \lim_{J \rightarrow \infty} \|S_J[\mathcal{P}_J]f - S_J[\mathcal{P}_J]h\| \leq \|f - h\|.$$

Para ondeletas de dispersión admisibles que satisfacen (2.9), El Teorema 2.2 nos demuestra que si  $\|S_J[\mathcal{P}_J]f\| = \|f\|$  entonces  $\lim_{J \rightarrow \infty} \|S_J[\mathcal{P}_J]f\| = \|f\|$ . El siguiente teorema demuestra que el límite es invariante por traslaciones, pero para la demostración del teorema necesitaremos de un resultado auxiliar:

**Lema 3.2.** Existe una constante  $C$  tal que para todo  $\tau \in \mathcal{C}^2(\mathbb{R}^d)$  con  $\|\nabla \tau\|_\infty \leq \frac{1}{2}$  se tiene que

$$\|L_\tau A_J f - A_J f\| \leq C \|f\| 2^{-J} \|\tau\|_\infty.$$

*Demostración.* En esta prueba, al igual que en otras cotas superiores para normas, vamos a necesitar el Lema de Schur [QV18]. De esta manera, el Lema de Schur nos recuerda que para cualquier operador  $Kf(x) = \int f(u)k(x, u)du$  se tiene

$$\int |k(x, u)|dx \leq C,$$

y además

$$\int |k(x, u)|du \leq C \implies \|K\| \leq C.$$

Dónde  $\|K\|$  es la norma en  $L^2(\mathbb{R}^d)$  de  $K$ .

El operador norma de  $k_J = L_\tau A_J - A_J$  se calcula aplicando el lema de Schur a su kernel,

$$k_J(x, u) = \phi_{sJ}(x - \tau(x) - u) - \phi_{2J}(x - u).$$

Si nos fijamos en la expresión anterior, cuando  $x = 0 = u$  se tiene que:

$$k_J(0, 0) = \phi_{sJ}(0) - \phi_{2J}(0) = 0.$$

Si ahora calculamos su serie de primer orden de Taylor centrado en el  $(0, 0)$  se obtiene:

$$k_J = k_J(0, 0) + \int_0^1 \nabla \phi_{2J}(x - t\tau(x) - u) \tau(x).dt$$

Si ahora calculamos el módulo obtenemos que:

$$\begin{aligned}
|k_J| &= |k_J(0,0) + \int_0^1 \nabla \phi_{2^J}(x - t\tau(x) - u)\tau(x)dt| \\
&\leq |k_J(0,0)| + \left| \int_0^1 \nabla \phi_{2^J}(x - t\tau(x) - u)\tau(x)dt \right| \\
&\leq \left| \int_0^1 \nabla \phi_{2^J}(x - t\tau(x) - u)\tau(x)dt \right| \\
&\leq \int_0^1 |\nabla \phi_{2^J}(x - t\tau(x) - u)\tau(x)| dt = |\tau(x)| \int_0^1 |\nabla \phi_{2^J}(x - t\tau(x) - u)| dt \\
&\leq \|\tau(x)\|_\infty \int_0^1 |\nabla \phi_{2^J}(x - t\tau(x) - u)| dt.
\end{aligned}$$

Si ahora integramos en  $u$  y aplicamos el teorema de Fubini para intercambiar las integrales del lado derecho de la desigualdad obtenemos:

$$\int |k_J| du \leq \|\tau(x)\|_\infty \int \int_0^1 |\nabla \phi_{2^J}(x - t\tau(x) - u)| dt du = \|\tau(x)\|_\infty \int_0^1 \int |\nabla \phi_{2^J}(x - t\tau(x) - u)| du dt.$$

por otro lado, vamos a comprobar que

$$\nabla \phi_{2^J}(x) = 2^{-dJ-J} \nabla \phi(2^{-J}x).$$

Para ello debemos recordar que  $\phi_{2^J}(x) = 2^{-dJ} \phi(2^{-J}x)$  luego

$$\begin{aligned}
\nabla \phi_{2^J}(x) &= \nabla(2^{-dJ} \phi(2^{-J}x)) \\
&= 2^{-dJ} \nabla(\phi(2^{-J}x)).
\end{aligned}$$

Si nos fijamos, debido a que  $x$  está multiplicado por  $2^{-J}$  en cada componente del vector, siempre que derivemos con respecto a alguna componente, vamos a poder sacar como factor común  $2^{-J}$  por lo tanto:

$$\nabla \phi_{2^J}(x) = 2^{-dJ-J} \nabla(\phi(2^{-J}x)).$$

De esta forma, realizando un cambio de variable tendríamos:

$$\begin{aligned}
\int |k_J| du &\leq \|\tau(x)\|_\infty 2^{-dJ-J} \int |\nabla \phi(2^J u')| du' \\
&= 2^{-J} \|\tau(x)\|_\infty \|\nabla \phi\|_1.
\end{aligned}$$

Si ahora realizamos el mismo procedimiento integrando en  $x$  en vez de en  $u$  tenemos que

$$\int |k_J(x, u)| dx \leq \|\tau(x)\|_\infty \int_0^1 \int |\nabla \phi_{2^J}(x - t\tau(x) - u)| dx dt$$

### 3. Invarianza por Traslaciones

Si ahora aplicamos el cambio de variable  $v = x - t\tau(x)$  y calculamos su Jacobiano

$$\begin{aligned} Jv &= J(x - t\tau(x)) = J(x) - J(t\tau(x)) \\ &= Id - tJ(\tau(x)) \\ &= Id - t\nabla\tau(x). \end{aligned}$$

Vamos a buscar una cota para el determinante del Jacobiano

$$\begin{aligned} |J| &= (1 - t\tau(x))^d \\ &\geq (1 - \|\tau\|_\infty)^d \\ &\geq 2^{-d}. \end{aligned}$$

Aplicando ahora el cambio de variable a la integral

$$\begin{aligned} \int |k_J(x, u)| dx &\leq \|\tau(x)\|_\infty 2^d \int_0^1 \int |\nabla\phi_{2J}(v - u)| dv dt \\ &= 2^{-J} \|\tau\|_\infty \|\nabla\phi\|_1 2^d. \end{aligned}$$

De las dos cotas superiores obtenidas esta es la mayor, por lo que aplicamos el lema de Schur a esta y terminamos la demostración del lema

$$\|L_\tau A_J - A_J\| \leq 2^{-J+d} \|\nabla\phi\|_1 \|\tau\|_\infty.$$

□

Con esto ya tenemos todas las herramientas necesarias para enunciar y demostrar el teorema central de esta sección, aquel que nos garantiza que el operador que estamos construyendo que modeliza una red neuronal convolucional es invariante a traslaciones.

**Teorema 3.1.** *Para ondeletas de dispersión admisibles se tiene que*

$$\forall f \in L^2(\mathbb{R}^d), \forall c \in \mathbb{R}^d \quad \lim_{J \rightarrow \infty} \|S_J[\mathcal{P}_J]f - S_J[\mathcal{P}_J]L_c f\| = 0$$

*Demostración.* Fijamos  $f \in L^2(\mathbb{R}^d)$ . Teniendo en cuenta la conmutatividad  $S_J[\mathcal{P}_J]L_c f = L_c f S_J[\mathcal{P}_J]$  y la definición  $S_J[\mathcal{P}_J]f = A_J U[\mathcal{P}_J]f$ ,

$$\begin{aligned} \|S_J[\mathcal{P}_J]L_c f - S_J[\mathcal{P}_J]f\| &= \|L_c A_J U[\mathcal{P}_J]f - A_J U[\mathcal{P}_J]f\| \\ &\leq \|L_c A_J - A_J\| \|U[\mathcal{P}_J]f\|. \end{aligned}$$

Si ahora aplicamos el **Lema 3.2** con  $\tau = c$ , se tiene que  $\|\tau\|_\infty = |c|$  y además

$$\|L_c A_J - A_J\| \leq C 2^{-J} |c|.$$

Y si tenemos en cuenta esto en la expresión anterior nos da que:

$$\begin{aligned} \|S_J[\mathcal{P}_J]L_c f - S_J[\mathcal{P}_J]f\| &\leq \|L_c A_J - A_J\| \|U[\mathcal{P}_J]f\| \\ &\leq C 2^{-J} |c| \|U[\mathcal{P}_J]f\| \end{aligned}$$

Como la admisibilidad de la condición (2.9) se satisface, **Lema 2.5** se demuestra en (2.10) que para  $J > 1$

$$\frac{\alpha}{2} \|U[\mathcal{P}_J]f\|^2 \leq (J+1) \|f\|^2 + \|f\|_w^2.$$

Y de esta expresión podemos sacar una cota superior para  $\|U[\mathcal{P}_J]f\|$ :

$$\|U[\mathcal{P}_J]f\|^2 \leq ((J+1) \|f\|^2 + \|f\|_w^2) 2\alpha^{-1}$$

Si  $\|f\|_w < \infty$  entonces elevando al cuadrado en la desigualdad de antes tenemos

$$\|S_J[\mathcal{P}_J]L_c f - S_J[\mathcal{P}_J]f\|^2 \leq ((J+1) \|f\|^2 + \|f\|_w^2) C^2 2\alpha^{-1} 2^{-2J} |c|^2,$$

y tomando límite en ambo lados cuando  $J \rightarrow \infty$  tenemos que

$$\begin{aligned} \lim_{J \rightarrow \infty} \|S_J[\mathcal{P}_J]L_c f - S_J[\mathcal{P}_J]f\|^2 &\leq \lim_{J \rightarrow \infty} ((J+1) \|f\|^2 + \|f\|_w^2) C^2 2\alpha^{-1} 2^{-2J} |c|^2 \\ &= 0. \end{aligned}$$

Luego  $\lim_{J \rightarrow \infty} \|S_J[\mathcal{P}_J]L_c f - S_J[\mathcal{P}_J]f\| = 0$ .

Finalmente vamos a probar ahora que el límite anterior se da  $\forall f \in L^2(\mathbb{R}^d)$ , con un argumento similar al de la prueba del **Teorema 2.2**. Cualquier  $f \in L^2(\mathbb{R}^d)$  se puede escribir como el límite de una sucesión de funciones  $\{f_n\}_{n \in \mathbb{N}}$  con  $\|f_n\|_w < \infty$ , y como  $S_J[\mathcal{P}_J]$  es no expansivo y  $L_c$  es unitario, se puede verificar que

$$\|L_c S_J[\mathcal{P}_J]f - S_J[\mathcal{P}_J]f\| \leq \|L_c S_J[\mathcal{P}_J]f_n - S_J[\mathcal{P}_J]f_n\| + 2\|f - f_n\|.$$

Haciendo tender  $n \rightarrow \infty$  se prueba que  $\lim_{J \rightarrow \infty} \|S_J[\mathcal{P}_J]f - S_J[\mathcal{P}_J]L_c f\| = 0$  con lo que acaba la demostración.  $\square$





## 4. Conclusiones

- La memoria debe realizarse con un procesador de texto científico, preferiblemente (La)TeX.
- La portada debe contener el logo de la UGR, incluir el título del TFG, el nombre del estudiante y especificar el grado, la facultad y el curso actual.
- La contraportada contendrá además el nombre del tutor o tutores.
- La memoria debe necesariamente incluir:
  - un índice detallado de capítulos y secciones,
  - un resumen amplio en inglés del trabajo realizado (se recomienda entre 800 y 1500 palabras),
  - una introducción en la que se describan claramente los objetivos previstos inicialmente en la propuesta de TFG, indicando si han sido o no alcanzados, los antecedentes importantes para el desarrollo, los resultados obtenidos, en su caso y las principales fuentes consultadas,
  - una bibliografía final que incluya todas las referencias utilizadas.
- Se recomienda que la extensión de la memoria sea entre 30 y 60 páginas, sin incluir posibles apéndices.

Para generar el pdf a partir de la plantilla basta compilar el fichero `libro.tex`. Es conveniente leer los comentarios contenidos en dicho fichero pues ayudarán a entender mejor como funciona la plantilla.

La estructura de la plantilla es la siguiente<sup>1</sup>:

- Carpeta **preliminares**: contiene los siguientes archivos
  - dedicatoria.tex** Para la dedicatoria del trabajo (opcional)
  - agradecimientos.tex** Para los agradecimientos del trabajo (opcional)
  - introduccion.tex** Para la introducción (obligatorio)
  - summary.tex** Para el resumen en inglés (obligatorio)
  - tablacontenidos.tex** Genera de forma automática la tabla de contenidos, el índice de figuras y el índice de tablas. Si bien la tabla de contenidos es conveniente incluirla, el índice de figuras y tablas es opcional. Por defecto está desactivado. Para mostrar dichos índices hay que editar este fichero y quitar el comentario a `\listoffigures` o `\listoftables` según queramos uno de los índices o los dos. En este archivo también es posible habilitar la inclusión de un índice de listados de código (si estos han sido incluidos con el paquete `listings`)

---

<sup>1</sup>Los nombres de las carpetas no se han acentuado para evitar problemas en sistemas con Windows

## 4. Conclusiones

El resto de archivos de dicha carpeta no es necesario editarlos pues su contenido se generará automáticamente a partir de los metadatos que agreguemos en `libro.tex`

- Carpeta **capitulos**: contiene los archivos de los capítulos del TFG. Añadir tantos archivos como sean necesarios. Este capítulo es `capitulo01.tex`.
- Carpeta **apendices**: Para los apéndices (opcional)
- Carpeta **img**: Para incluir los ficheros de imagen que se usarán en el documento.
- Carpeta **paquetes**: Incluye dos ficheros
  - hyperref.tex** para la configuración de hipervínculos al generar el pdf (no es necesario editarlo)
  - comandos-entornos.tex** donde se pueden añadir los comandos y entornos personalizados que precisemos para la elaboración del documento. Contiene algunos ejemplos
- Fichero `library.bib`: Para incluir las referencias bibliográficas en formato bibtex. Son útiles las herramientas [doi2bib](#) y [OttoBib](#) para generar de forma automática el código bibtex de una referencia a partir de su DOI o su ISBN. Para que una referencia aparezca en el pdf no basta con incluirla en el fichero `library.bib`, es necesario además *citarla* en el documento usando el comando `\cite`. Si queremos mostrar todas las referencias incluidas en el fichero `library.bib` podemos usar `\cite{*}` aunque esta opción no es la más adecuada. Se aconseja que los elementos de la bibliografía estén citados al menos una vez en el documento (y de esa forma aparecerán de forma automática en la lista de referencias).
- Fichero `glosario.tex`: Para incluir un glosario en el trabajo (opcional). Si no queremos incluir un glosario deberemos borrar el comando `\input{glosario.tex}` del fichero `libro.tex` y posteriormente borrar el fichero `glosario.tex`
- Fichero `libro.tex`: El documento maestro del TFG que hay que compilar con  $\text{\LaTeX}$  para obtener el pdf. En dicho documento hay que cambiar la *información del título del TFG y el autor así como los tutores*.

Finalmente y de forma también opcional se puede incluir un índice terminológico. Por defecto dicha opción está deshabilitada. Para habilitar la inclusión de dicho índice terminológico basta con quitar los comentarios a las líneas finales de `libro.tex` y cargar el paquete `makeindex` en el preámbulo del documento (ver comentarios en `libro.tex`)

## 4.1. Elementos del texto

En esta sección presentaremos diferentes ejemplos de los elementos de texto básico. Conviene consultar el contenido de `capitulos/capitulo01.tex` para ver cómo se han incluido.

### 4.1.1. Listas

En  $\text{\LaTeX}$  tenemos disponibles los siguientes tipos de listas:

Listas enumeradas:

1. item 1

2. item 2

3. item 3

Listas no enumeradas

■ item 1

■ item 2

■ item 3

Listas descriptivas

**termino1** descripción 1

**termino2** descripción 2

### 4.1.2. Tablas y figuras

En la **Tabla 4.1** o la **Figura 4.1** podemos ver...

| Agrupados |          |          |
|-----------|----------|----------|
| cabecera  | cabecera | cabecera |
| elemento  | elemento | elemento |
| elemento  | elemento | elemento |
| elemento  | elemento | elemento |

Tabla 4.1.: Ejemplo de tabla



UNIVERSIDAD  
DE GRANADA

Figura 4.1.: Logotipo de la Universidad de Granada

## 4.2. Entornos matemáticos

**Teorema 4.1.** *Esto es un ejemplo de teorema.*

#### 4. Conclusiones

**Proposición 4.1.** *Ejemplo de proposición*

**Lema 4.1.** *Ejemplo de lema*

**Corolario 4.1.** *Ejemplo de corolario*

**Definición 4.1.** *Ejemplo de definición*

*Observación 4.1.* *Ejemplo de observación*

Y esto es una referencia al **Teorema 4.1.**

Identidad Pitagórica (4.1)

$$\cos^2 x + \sin^2 x = 1 \quad (4.1)$$

La fórmula de Gauss-Bonnet para una superficie compacta  $S$  viene dada por:

$$\int_S K = 2\pi\chi(S)$$

### 4.3. Bibliografía e índice

Además incluye varias entradas al índice alfabético mediante el comando `\index`

## **Parte II.**

### **Localización de landmarks cefalométricos por medio de técnicas de few-shot learning**



## 5. Introducción

### 5.1. Introducción

Las **ciencias forenses** son aquellas que aplican el método científico a hechos presuntamente delictivos con la finalidad de aportar pruebas a efectos judiciales. Este campo es interdisciplinar que incluye principalmente a la Criminalística<sup>1</sup> y la Medicina Forense<sup>2</sup>.

Así pues, este trabajo ubica en el ámbito de la **antropología forense**, que es una rama de la Medicina Forense que se encarga de determinar la edad, raza, sexo o estatura, entre otras, a partir de restos óseos en problemas de reconstrucción facial, identificación de víctimas en desastres en masa o en identificación facial.

#### 5.1.1. Descripción del problema

La **Superposición Craneofacial** es una técnica de identificación forense mediante la cual se comparan imágenes de la persona difunta<sup>3</sup> con una o varias imágenes de un cráneo candidato. La técnica empleada es la superposición de ambas imágenes y se estima si son o no la misma persona de acuerdo a correspondencias morfológicas o marcando puntos de referencia. Los *landmarks* o puntos de referencia, pueden situarse en el cráneo<sup>4</sup> encontrado o en el rostro<sup>5</sup>. Entre los dos tipos de *landmarks* anteriores existe una correlación, en caso de pertenecer a la misma persona, que el antropólogo forense trata de descubrir.

Esta tarea no es sencilla debido al **tejido blando facial** que separa el punto craneométrico de su homólogo cefalométrico y que lo desplaza. El desplazamiento ocasionado por el tejido blando facial no es constante ni se produce siempre en la misma dirección, lo cual junto con otros factores como la grasa o la calidad de la imagen complica esta tarea de superponer las dos imágenes (de cráneo y cara) con fidelidad.

Tradicionalmente, el proceso era esencialmente manual y complicado de replicar, y pese a los avances actuales que se están llevando a cabo para automatizar esta tarea [HIWK15], la identificación de *landmarks* sigue realizándose a mano normalmente.

En este contexto, el presente trabajo se centrará en esta etapa del marcado de *landmarks*, en concreto de **landmarks cefalométricos** (en las imágenes ante-mortem). El objetivo será comparar dos frameworks que utilizan técnicas de **Deep Learning** para la detección y marcado de **landmarks cefalométricos**

---

<sup>1</sup>Disciplina encargada del descubrimiento y verificación científica de presuntos hechos delictivos y quienes los cometen.

<sup>2</sup>Disciplina encargada de determinar el origen de las lesiones, las causas de muerte o la identificación de seres humanos vivos o muertos.

<sup>3</sup>A estas imágenes se le denominan imágenes ante-mortem

<sup>4</sup>En este caso reciben el nombre de puntos craneométricos

<sup>5</sup>En este caso se denominan puntos cefalométricos

*5. Introducción*

**5.1.2. Motivación**

**5.1.3. Objetivos**



## 6. Fundamentos Teóricos

En esta sección vamos a introducir cuales serían los conceptos teóricos más importantes que conviene tener presentes para la correcta comprensión del trabajo y sus resultados. Para ello se ha recurrido al conocimiento adquirido en asignaturas como **Visión por Computador**, **Aprendizaje Automático** así como diversos artículos que se citarán dónde sea conveniente.

### 6.1. Aprendizaje Automático

Actualmente la **Inteligencia Artificial** (IA) es una rama de la informática muy popular y de gran importancia que pretende dotar a los ordenadores de una manera de razonar o solucionar problemas inteligente. En este contexto, la IA ha explorado diversos métodos para conseguir este propósito como son el estudio de Metaheurísticas, la Ingeniería del Conocimiento y más recientemente el conocido **Aprendizaje Automático** (AA).

Los métodos que empleamos en este trabajo pertenecen a la rama del AA, y por lo tanto es importante comenzar definiendo qué es este concepto. Para ello, disponemos de diversas definiciones proporcionadas por distintos autores:

La primera y más clásica nos la proporciona Arthur Samuel en 1959, en la cual define el AA como **el campo de estudio que da a los ordenadores la capacidad de aprender sin ser programados explícitamente**. Esta definición es muy general, pero nos permite hacernos una idea de lo que pretende conseguir este campo de estudio, que es dotar a los ordenadores de la capacidad de “*aprender*”, generalmente a partir de una base de datos, con la idea de poder usar este conocimiento adquirido durante el aprendizaje para resolver casos nuevos del problema que la máquina no conozca previamente.

Una definición un poco más reciente de Tom Mitchell (1998) nos dice que: **Un programa de ordenador se dice que aprende de la experiencia E respecto de alguna tarea T y alguna medida de rendimiento P, si su rendimiento en T, medido por P, mejora con la experiencia E**. Esta segunda definición nos permite identificar los elementos necesarios para poder resolver un problema mediante técnicas de AA. Así, en primer lugar necesitamos una tarea (T) que queremos resolver con ayuda de un ordenador, una experiencia (E) en esa tarea, que generalmente es una base de datos asociada al problema, y una medida de rendimiento (P) que generalmente se asocia con una función objetivo que se pretende minimizar/maximizar.

Tradicionalmente, los algoritmos de AA se dividen en dos conjuntos:

- Aprendizaje Supervisado.
- Aprendizaje no Supervisado.

No obstante, han aparecido otras técnicas más recientes como el Aprendizaje por Refuerzo que son muy interesantes y usadas actualmente, pero no vamos a profundizar en ellas pues no son necesarias para el trabajo que nos ocupa.

### 6.1.1. Aprendizaje Supervisado

Los algoritmos de AA que se emplean en este conjunto se caracterizan porque disponen de una base de datos **etiquetados** de manera que para cada dato  $x$  conocemos su etiqueta asociada  $y$ , y nuestro objetivo sería tratar de conocer la función  $f$  que los relaciona, de manera que  $f(x) = y$ .

Dentro de este grupo podemos encontrar problemas de **regresión** y de **clasificación**.

#### 6.1.1.1. Regresión

En los problemas de regresión se pretende obtener la función  $f$  que asocia correctamente a cada dato su etiqueta:

$$f(x) = y \text{ con } x \in \mathbb{R}^m \text{ y } y \in \mathbb{R}^n$$

Generalmente, obtener la función  $f$  exacta es complicado, por lo que se pretende aproximar mediante una función  $f'$  que elegimos y que entrenaremos a partir de los datos etiquetados que se nos proporcionan. Volviendo a la definición de Tom Mitchell, en este tipo de problemas tendríamos que

- T= regresión (aproximar  $f$ )
- E= El conjunto de datos  $X$  etiquetados que se proporcionan para entrenar el modelo  $f'$ .
- P= función de coste asociada (generalmente se emplea el error cuadrático medio) que nos mide lo “bien” que nuestra función  $f'$  aproxima a  $f$ .

Por ejemplo el si intentamos predecir  $f$  mediante un modelo lineal:

$$f'(x) = w^T x \text{ } x, w \in \mathbb{R}^m$$

Disponemos de un conjunto de  $N$  datos

$$X = \{x_1, x_2, \dots, x_N\} \text{ } x_i \in \mathbb{R}^m$$

Además de un conjunto de etiquetas

$$Y = \{y_1, y_2, \dots, y_N\} \text{ } y_i \in \mathbb{R}^n$$

Y usamos como medida de error el error cuadrático medio:

$$J(\alpha) = \frac{1}{N} \sum_{i=1}^N (f'(x_i) - f(x_i))^2 = \frac{1}{N} \sum_{i=1}^N (y'_i - y_i)^2$$

Dónde  $y'_i$  es la etiqueta predicha por  $f'$  para  $x_i$ .

Nuestro objetivo sería encontrar el vector de pesos  $w$  que minimice la función de coste  $J$  y para ello utilizamos los datos de entrenamiento  $X$ .

### 6.1.1.2. clasificación

Por otro lado tenemos los problemas de clasificación, en los datos se encuentran agrupados en clases y se pretende clasificar cada dato de entrada en la clase correcta. Los casos más sencillos de este problema son los de **clasificación binaria**, y en ellos se pretende agrupar los datos en dos posibles clases que suelen codificarse como 0 y 1.

### 6.1.2. Aprendizaje no Supervisado

El aprendizaje no supervisado se caracteriza porque los datos que se proporcionan no están etiquetados, y no se busca una salida concreta, sino que se pretende analizar las características de nuestro conjunto de datos.

Así, por ejemplo, tareas que pueden resolverse con esta técnica pueden ser la agrupación de clientes de cierta compañía en distintas clases según sus características.

### 6.1.3. Nuestro Problema

En nuestro problema, los frameworks de los que disponemos resuelven problemas de aprendizaje supervisado y no supervisado.

Por ejemplo vamos a intentar predecir los landmarks cefalométricos para una cierta imagen de entrada, lo que nos llevaría a un problema típico de aprendizaje supervisado en el que pretendemos a partir de la imagen de entrada conocer la función que nos proporciona la salida correcta (la imagen con los landmarks marcados correctamente).

Por otro lado, uno de nuestros frameworks tiene una etapa de entrenamiento previa al problema de los landmarks en la cual mediante conjuntos de datos de imágenes sin etiquetar de rostros humanos, se pretende reconstruir imágenes preservando al máximo posible la estructura de la cara. Esto, como podemos ver, es un problema típico de aprendizaje no supervisado, porque no se busca obtener una etiqueta para cada imagen, sino analizar la estructura de los distintos elementos de los datos de entrada para ser capaces de reconstruirlos preservando su estructura.

### 6.1.4. Gradiente Descendente

En esta sección hemos hablado de qué es el AA y cómo se formalizan sus problemas para poder resolverlos. Y en concreto hemos formalizado cómo se resuelven los problemas de regresión en los que queríamos aproximar una función desconocida  $f$  a partir de una aproximación  $f'$  y en base a una función de coste. Sin embargo, no hemos hablado de ningún algoritmo que se use en la minimización de dicha función de coste. Es por ello que vamos a explicar el principal algoritmo que se utiliza para esta tarea, el **Gradiente Descendente**.

El Gradiente descendente es un algoritmo clásico que persigue la idea intuitiva de que el gradiente de una función siempre “apunta” hacia el máximo de esta, por lo que seguir la dirección contraria a este nos llevará al mínimo de la función. Más formalmente, si recuperamos la notación del apartado **Subsubsección 6.1.1.1** tendríamos:

La función objetivo es:

$$f(x) = y \quad x \in \mathbb{R}^m \quad y \in \mathbb{R}^n$$

## 6. Fundamentos Teóricos

La función con la que vamos a intentar aproximar la función objetivo es:

$$f'(x, w) = y \quad x \in \mathbb{R}^m \quad y \in \mathbb{R}^n \quad w \in \mathbb{R}^d$$

La función de coste sería  $J(w)$  que de alguna manera mide la distancia entre  $f$  y  $f'$  y que para poder aplicar el método debe ser derivable. Algunas funciones de coste usuales son:

- La función **L2** (también conocida como error cuadrático medio):

$$J(w) = \frac{1}{N} \sum_{i=1}^N (f(x_i, w) - f'(x_i))^2$$

- La función **L1** (también conocida como error absoluto medio):

$$J(w) = \frac{1}{N} \sum_{i=1}^N |f(x_i, w) - f'(x_i)|$$

Una vez hemos formalizado el problema, el algoritmo **Gradiente Descendente** consiste en:

- Se inicializa el vector de pesos  $w$ .
- En cada paso  $i$  del entrenamiento, el vector de pesos del siguiente paso  $i + 1$  se calcula de acuerdo a la siguiente relación:

$$w_{i+1} = w_i - \eta \nabla J(w)$$

Dónde  $\eta$  es un factor conocido como **learning rate**(lr) que mide el “*tamaño*” del paso que en cada iteración damos en búsqueda del mínimo.

Idealmente, con este método se encuentra un mínimo global de la función de coste en el caso en que esta sea convexa. En caso de no serlo podría caer en un mínimo local en su lugar.

Por otro lado, cabe destacar la importancia de una buena elección del **learning rate**, pues si este es demasiado pequeño puede ocasionar una lenta convergencia al mínimo, y por lo tanto que se realice un gran número de iteraciones, y en cambio un valor excesivamente grande de este puede impedir la convergencia, pues los saltos serían tan grandes en la dirección del mínimo local o global que podría llegar a “saltar” por encima de este siempre. Por lo tanto una técnica habitual aunque costosa de este algoritmo consiste en usar un learning rate adaptativo, que sea mayor en las primeras iteraciones y que vaya disminuyendo conforme se incrementa el número de iteraciones (pues se entiende que se estará cerca del mínimo).

### 6.1.4.1. Gradiente Descendente Estocástico

El algoritmo descrito anteriormente tiene el problema de ser costoso computacionalmente, debido a que en cada iteración se debe calcular la función de coste para todos los ejemplos del conjunto de entrenamiento  $X$ . Es por ello que suele emplearse en su lugar una versión modificada y que sigue dando buenos resultados que consiste en actualizar los pesos en base a unos pocos ejemplos del conjunto de entrenamiento  $X$  que se conoce como “*minibatch*”.

## 6.2. Visión por Computador

La **Visión por computador** es un área de conocimiento en el que se unen diversas disciplinas como la IA o el AA para un propósito común, que es el procesamiento de imágenes por medio de un ordenador con la finalidad de que la máquina pueda llegar a extraer información relativa a estas del mismo modo en que lo haría un ser humano [Ros88].

Problemas clásicos de la visión por computador son el reconocimiento de objetos o personas en imágenes, la segmentación o la clasificación. Así pues, podemos ver la relación directa que hay entre nuestro objetivo y esta disciplina, pues los frameworks que usaremos tendrán por objetivo extraer información de imágenes de rostros de personas para posteriormente tratar de identificar en ellos con el mayor grado de decisión posible una serie de landmarks cefalométricos que el sistema ha aprendido a base de unos ejemplos etiquetados (AA).

Finalmente, en los últimos años esta rama ha experimentado un fuerte crecimiento e importancia en la comunidad científica debido al actual desarrollo del **Deep Learning** y las **redes convolucionales profundas** que explicaremos en detalle en la siguiente sección. Estas nuevas herramientas han permitido crear programas que obtienen un gran rendimiento en el tratamiento de imágenes. Ejemplo de ello son los dos frameworks que vamos a comparar en este trabajo.

## 6.3. Deep Learning

Como ya se ha mencionado anteriormente, la IA se encuentra muy desarrollada actualmente y es capaz de resolver problemas que tradicionalmente eran muy complicados para ser resueltos por un humano, pero que se ha demostrado que no son tan complicados para una máquina. Sin embargo, e irónicamente, algunas de las tareas más fáciles para los seres humanos como son el reconocimiento del habla o la identificación de objetos en imágenes han suponen un verdadero reto para un ordenador, y o ha sido hasta los últimos años con el nacimiento del **Deep Learning** que se han empezado a obtener resultados satisfactorios en este campo.

Por lo tanto, los algoritmos del Deep Learning se caracterizan por resolver estos problemas a partir de representaciones del mismo que se expresan en terminos de otras más simples. De esta manera se pueden construir conceptos difíciles a partir de otros más sencillos. Este grafo puede ser tan profundo como se necesite, por ello se le conoce como Deep Learning.

### 6.3.1. Redes Neuronales

La arquitectura básica de los modelos de Deep Learning viene descrita por la arquitectura de una **red neuronal**. Es por ello que vamos a profundizar un poco en esta estructura y para ello vamos a partir de un ejemplo clásico como es el **Perceptrón multicapa**(MLP). Para esta sección vamos a seguir el capítulo 6 de [GBC16].

Las redes neuronales tienen por objetivo aproximar una función desconocida  $f(x) = y$  que asocia a cada entrada  $x$  una salida  $y$  a partir de una función  $f'(x; W) = \hat{y}$  (dónde  $\hat{y}$  es la etiqueta predicha para la entrada  $x$ ) que depende de unos parámetros  $W$ , de manera que el objetivo es aprender los valores de  $W$  que mejor aproximan la función objetivo  $f$ .

Se denominan algoritmos **feedforward** porque la información fluye desde la entrada  $x$  a través de los cálculos intermedios que definen  $f'$  hasta finalmente dar una salida  $y$ .

Finalmente a estos algoritmos se les denomina **redes** porque generalmente se representan como una composición de distintas funciones en cadena de manera que se van aplicando sucesivamente sobre la entrada  $x$  hasta la salida  $\hat{y}$ .




Figura 6.1.: Red neuronal con una capa oculta. Formalmente podría describirse como  $f'(x) = (f_3(f_2(f_1(x))))$ , dónde  $f_1$  hace referencia a la capa de entrada a la red,  $f_2$  a la capa oculta y  $f_3$  a la capa de salida.

La **profundidad** de la red vendría dada por la cantidad de **capas ocultas** que esta tiene. En los algoritmos de Deep Learning veremos un gran número de capas ocultas, de ahí el nombre.

Por otro lado, cada capa contiene un número determinado de **neuronas**, que se relacionan con las de la capa siguiente y las de la capa anterior mediante combinaciones lineales generalmente. Sin embargo, estas combinaciones lineales no son suficientes para que la red pueda aproximar funciones objetivo  $f$  que sean no-lineales, para ello se emplean las llamadas **funciones de activación**. Se tratan de un conjunto de funciones no-lineales entre las que destacan las siguientes [SSA17]:

- **Función Sigmoide.** Transforma los valores de entrada a un valor entre 0 y 1.

$$\text{Sigmoide}(x) = \frac{1}{e^{-x}}$$

- **Función Tangente Hiperbólica.** Es similar a la función sigmoide, pero es simétrica respecto al origen.

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

- **Función ReLU.** Es una de las más usadas en redes neuronales por ser de las más eficientes, ya que permite que no se activen todas las neuronas a la vez, ya que en aquellas cuya salida tras la combinación lineal con los pesos de la capa correspondiente sea o no serán activadas.

$$\text{ReLU}(x) = \max(0, x)$$

Existe el problema de que en algunos casos, el gradiente de la función sea 0 debido a

que los pesos no se actualicen durante el proceso que explicaremos más adelante de **back-propagation**.

- **Función Leaky ReLU**. Es una versión mejorada de la función anterior, ya que para los casos en los que la función anterior valía 0, ahora se expresan como una componente lineal de la entrada  $x$  muy pequeña, de esta manera se resuelve el problema de que el gradiente de la función sea 0.

$$\text{LeakyReLU}(x) = \begin{cases} x & \text{si } x \leq 0 \\ ax & \text{si } 0 < x \end{cases}$$

Dónde  $a$  es un valor muy próximo a 0.

- **Función SoftMax**. Es una combinación de múltiples funciones sigmoide. Mientras que la función Sigmoide se usa en problemas de clasificación binaria, la función SoftMax permite que se pueda realizar clasificación multiclase, ya que transforma un vector de entrada  $K$ -dimensional de valores reales en un vector  $K$ -dimensional de elementos entre 0 y 1, de manera que la componente más próxima a 1 podría entenderse como la clase a la que pertenecería el elemento en un problema de clasificación multiclase.

$$\sigma(x)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} \quad j = 1, \dots, K$$

No existe una manera de elegir la mejor función para cada caso, pero de forma experimental se ha podido comprobar que la función ReLU en general da buenos resultados y si hubiera demasiadas neuronas muertas en la red podría cambiarse por la Leaky ReLU.

De esta manera, en la capa  $i$  de la red, la función  $f_i$  suele tener la siguiente expresión:

$$f_i(x) = \gamma(w_i^T x)$$

Dónde  $\gamma$  representa una función cualquiera del conjunto de funciones de activación que hemos descrito antes y  $w_i$  el vector de pesos correspondiente a la capa  $i$  de la red.

### 6.3.2. Back Propagation

Todas las funciones de las capas intermedias de la red son derivables, por lo que se podría calcular de forma explícita su expresión en cada caso, lo que ocurre es que este proceso es costoso computacionalmente. En lugar de esto se aplica la técnica de **Back-propagation**.

Para entender este proceso correctamente se debe introducir primero el concepto de **Grafo Computacional**, que no es otra cosa que representar una función mediante un grafo. Como por ejemplo [Figura 6.2](#).

La idea del algoritmo de Back-propagation es ir calculando la derivada en cada nodo del grafo computacional mediante la aplicación de la regla de la cadena, de manera que si  $f(x, y, z) = g(x, y)h(z)$  si quisiéramos calcular  $\frac{\partial f}{\partial x}$  aplicando la regla de la cadena tendríamos que:

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial g} \frac{\partial g}{\partial x}$$

## 6. Fundamentos Teóricos

Backpropagation: a simple example

$$f(x, y, z) = (x + y)z$$

e.g.  $x = -2, y = 5, z = -4$




Figura 6.2.: Ejemplo de Grafo computacional junto con la salida para una entrada concreta  $x = -2, y = 5, z = -4$ . La imagen ha sido extraída del curso [Fei17].

Podemos entender mejor el proceso resolviendo el ejemplo Figura 6.2:




Figura 6.3.: Como podemos ver en la imagen superior, en primer lugar se renombra la salida de la operación  $x + y$  por  $q$ , de manera que  $f = qz$ . Tras esto se empiezan a calcular las derivadas parciales correspondientes desde el final hacia la entrada, aplicando cuando sea necesario la regla de la cadena hasta obtener la derivada de cada nodo en la imagen de abajo. Las imágenes han sido extraídas de [Fei17]

Como vemos en Figura 6.3, se produce un flujo desde la salida hacia la entrada en la que se van calculando los gradientes para cada parámetro. Una vez calculado el gradiente se procede a actualizar los pesos usando por ejemplo el algoritmo de **gradiente descendente**.



## 6.4. Redes Neuronales Convolucionales

Las **Redes Neuronales Convolucionales** (CNN) son la principal herramienta del Deep Learning y están inspiradas en las redes neuronales que hemos explicado anteriormente, con la salvedad de que ahora en vez de tener como entrada un vector de  $\mathbb{R}^d$  ahora pueden entrar a la red volúmenes de datos en varias dimensiones, como por ejemplo imágenes que se representan como una matriz 2D.

La principal motivación para la creación de estas redes es el concepto de **conectividad local**, pues cuando se trabaja con entradas de grandes dimensiones como son las imágenes, resulta impráctico conectar cada neurona con todas las de la capa anterior (como suele ocurrir en las redes neuronales clásicas que hemos visto anteriormente). Es por ello que se decide conectar cada neurona con una región local del volumen de entrada. Por lo que vamos a emplear filtros que siempre van a tener la misma profundidad que el volumen de entrada y que vamos a ir desplazando a lo largo del volumen de entrada. A continuación vamos a ver qué operación realizaremos con este filtro sobre el volumen de la imagen que ocupa para alimentar cada neurona de la siguiente capa.

Se denominan **Convolucionales** debido a que la principal operación matemática que realiza en cada filtro es la convolución. La operación de convolución se realiza generalmente entre dos funciones de variable real y viene descrita por la siguiente expresión:

$$f(t) = \int g(a)h(t-a)da = (g * h)(t)$$

Dónde  $t$  generalmente representa el paso del tiempo y  $x, w$  son dos funciones de variable real.

Sin embargo, la expresión anterior es la definición en el caso continuo, por lo que al trabajar en un ordenador, el tiempo y las funciones que empleamos deben ser discretizado, por ello consideraremos que  $t$  toma solo valores enteros. De esta forma, definimos la **convolución discreta** en una dimensión como:

$$f(t) = (g * h)(t) = \sum_{a=-\infty}^{\infty} g(a)h(t-a)$$

Sin embargo, en nuestro caso aplicaremos las CNN a imágenes, que se discretizan como matrices 2D, por lo que necesitamos extender la definición anterior al caso de dos dimensiones:

$$f(n, m) = (g * h)(n, m) = \sum_{j=-\infty}^{\infty} \sum_{i=-\infty}^{\infty} g(i, j)h(n-i, m-j)$$

La convolución tiene las siguientes propiedades:

- **Conmutatividad:**

$$f * g = g * f$$

- **Asociatividad:**

$$f * (g * h) = (f * g) * h$$

- **Distributividad:**

$$f * (g + h) = (f * g) + (f * h)$$

Con esto tenemos todos los ingredientes para empezar a describir la estructura de una CNN, que generalmente se compone de tres tipos de capas: **capas convolucionales**, **capas de Pooling** y **capas totalmente conectadas**.

#### 6.4.1. Capa Convolutiva

Se trata de la capa esencial de una CNN y consiste en desplazar un filtro por todo el volumen de entrada realizando la operación de convolución discreta en 2D. Como dijimos antes, la profundidad del filtro que empleamos para esto coincide con la del volumen de entrada siempre. Vamos a discutir ahora qué volumen de salida genera cada capa convolutiva que viene definido por tres parámetros: **depth**, **stride** y **padding**

- El parámetro **depth** se corresponde con el número de filtros que queremos aplicar al volumen de entrada, pues se pretende que cada uno de ellos aprenda algo distinto sobre este. Como cada filtro produce un volumen  $m \times n$  de profundidad 1 conocido como **mapa de activación**, este parámetro nos genera tantos mapas de activación como indique.
- El parámetro **stride** indica el paso con el que vamos desplazando cada filtro sobre el volumen de entrada, así un stride de 1 indica que el filtro se desplaza de uno en uno por los píxeles, y un stride de 2 indicaría que se desplaza de dos en dos. Cuanto mayor sea de menores dimensiones será el mapa de activación.
- El parámetro **padding** indica en cuantas filas y columnas se amplía el volumen de entrada antes de aplicar los filtros. Este parámetro se utiliza para controlar la dimensión de salida de los mapas de activación pues la convolución es una operación que reduce la dimensionalidad siempre.

Con todo esto en mente, la relación que determina el volumen de salida de una capa convolutiva para un volumen de entrada de dimensión  $W \times W \times d$  y empleando filtros de dimensión  $F \times F \times d$  con un padding  $P$ , un stride  $S$  sería:

$$Output = (W - F + 2P) / S + 1$$

Generalmente la salida de cada capa convolutiva supone la entrada a una función de activación como las que se describieron en [Subsección 6.3.1](#). Normalmente se utiliza la función ReLU, aunque también es común el uso de Leaky ReLU.

#### 6.4.2. Capa de Pooling

En las CNN es normal insertar de vez en cuando capas de Pooling. Esta capa reduce la dimensión del volumen de entrada y actúa independientemente del volumen de la profundidad que tenga el volumen de entrada. Generalmente se emplean filtros de dimensión  $2 \times 2$  con un stride de 2 que reduce a la mitad la dimensión del volumen de entrada y mantiene la profundidad.

El tipo de operación que se realiza con el filtro  $2 \times 2$  ha sido objeto de estudio en los últimos años, y se han probado las siguientes funciones:

- **Max Pooling**. Consiste en tomar el máximo de los cuatro elementos que ve el filtro del volumen de entrada.




Figura 6.4.: Ejemplo de cálculo de mapa de activación en una capa convolucional para un determinado volumen de entrada. El parámetro depth nos dice la cantidad de mapas de activación generamos para el volumen de entrada, o dicho de otro modo, el número de filtros que aplicamos. La imagen ha sido extraída de [Fei17]




Figura 6.5.: Sucesión de varias capas convolucionales + ReLU que describen la estructura básica de una CNN. Cabe destacar como la profundidad de los filtros es siempre la misma que la del volumen de entrada, de acuerdo a lo que hemos dicho anteriormente. La imagen han sido extraída de [Fei17]

- **Average Pooling.** Consiste en realizar un promedio de los elementos que ve el filtro.

Generalmente, el **max pooling** parece tener un mayor rendimiento en la práctica, pero esto aún es objeto de estudio.

### 6.4.3. Capa Totalmente Conectada (Fully Conected)

Generalmente al final de las CNN suele encontrarse una capa totalmente conectada (FC) que tiene la misma estructura que una red neuronal clásica con una o dos capas ocultas generalmente, y por lo tanto está creada para un vector de entrada de una dimensión concreta.

Como hemos visto en las capas anteriores, una CNN actúa de manera independiente de las dimensiones del volumen de entrada a la red salvo en las capas totalmente conectadas, es




Figura 6.6.: Ejemplo de capa de pooling usando la operación del máximo. La imagen han sido extraída de [Fei17]

por ello que estas capas son las que normalmente determinan el volumen de entrada a la red para que esta funcione correctamente.

#### 6.4.4. Batch Normalization

Actualmente, es muy común en las CNN usar **Batch Normalization** que consiste en normalizar los datos de entrada a cada capa convolucional con la intención de hacer que las operaciones convolucionales sean independientes unas de otras, es decir, que la distribución de los datos de entrada a una capa no dependa de los parámetros aprendidos por la capa anterior. Además este procedimiento ayuda a prevenir el overfitting de la red, ayudando a la regularización.

#### 6.4.5. Optimizador Adam

El proceso de aprendizaje en las CNN se realiza de manera similar al caso de las redes neuronales clásicas, mediante la técnica de Back-propagation. Sin embargo el optimizador Gradiente Descendente que hemos presentado en secciones anteriores tiene un único learning rate para todos los pesos de la red y se mantiene fijo durante todo el entrenamiento. Es por ello que en su lugar generalmente se usa el optimizador Adam que permite establecer un learning rate distinto para cada parámetro y que además es adaptativo.

#### 6.4.6. Proceso de entrenamiento de una CNN

Una vez aclarados todos los conceptos previos estamos en condiciones de comprender el proceso clásico de entrenamiento de una CNN en el que nos basaremos para entrenar nuestro modelo en secciones posteriores:

Generalmente se entrenan las imágenes por conjuntos denominados *mini-batches*, los cuales:

- En una primera instancia se propagan hacia adelante por toda la red calculando las activaciones y errores de salida en lo que se conoce como **forward pass**.
- Vamos de la salida a la entrada calculado los gradientes de cada unidad con lo que se conoce como **backward pass** aplicando el algoritmo de back-propagation.
- Se actualizan los pesos en base al gradiente calculado en el paso anterior y según el optimizador que se esté empleando (Adam, gradiente descendente, etc...)

### 6.4.7. Evolución de las CNN

Una vez hemos presentado las CNN y sus principales componentes vamos a dar un breve repaso por la historia y evolución de su arquitectura [Gup20].

#### 6.4.7.1. LeNet-5

La primera arquitectura conocida que forma parte de las CNN fue desarrollada por LeCun [LBBH98] para el reconocimiento de dígitos manuscritos, a dicha red la llamaron **LeNet-5** y fue la que sirvió de inspiración para el desarrollo de las posteriores redes.




Figura 6.7.: Arquitectura de la red LeNet. Como podemos observar tiene capas convolucionales, capas de average pooling y capas totalmente conectadas al final. Imagen extraída de [LBBH98].

Algunas de sus características eran:

- Su arquitectura consiste en:

$INPUT \rightarrow CONV \rightarrow AVG POOL \rightarrow CONV \rightarrow AVG POOL \rightarrow FC \rightarrow FC \rightarrow OUTPUT.$

- Las imágenes de entrada eran de dimensión  $32 \times 32$  y pertenecían a una base de datos MNIST de dígitos manuscritos.
- Tiene alrededor de unos 60000 parámetros para entrenar.
- Las dimensiones de la imagen de entrada descienden en cada paso mientras que la profundidad del tensor aumenta hasta llegar a las capas FC.

#### 6.4.7.2. AlexNet

Tras el éxito de LeNet comenzaron a desarrollarse nuevas arquitecturas basadas en CNN para problemas de reconocimiento de objetos en imágenes, aunque a pesar del buen rendimiento que tenían, resultaban muy costosas de entrenar para grandes volúmenes de datos o en imágenes de alta resolución. De esta manera surgió la red AlexNet [KSH12].

Destacan las siguientes propiedades:

- Tiene un total de ocho capas sin contar las de pooling, cinco convolucionales y tres FC.
- Emplea ReLU como función de activación en lugar de tanh pues se demuestra que acelera el proceso de entrenamiento  $\times 6$  y obtiene un error del 25% en el dataset CIFAR-10.




Figura 6.8.: Arquitectura de la red AlexNet. Destaca que parece estar “partida” en dos mitades, esto es porque por primera vez se usaron las GPUs para entrenar la red de manera que una GPU realizaba la parte superior de la arquitectura y otra la parte inferior. Imagen extraída de [KSH12].

- Se emplearon múltiples GPUs para el entrenamiento dividiendo las neuronas en dos conjuntos. Esto aceleró aún más el entrenamiento.
- Emplean la técnica de Max Pooling en lugar de la de Average Pooling de LeNet.
- Tienen 60 millones de parámetros que aprender, de manera que para evitar el Overfitting se usó la técnica de **dropout**, que consistía en “apagar” neuronas en cada iteración del entrenamiento de acuerdo a una probabilidad del 50 %. También se usó **data augmentation** que explicaremos en Subsección 6.6.1.
- El modelo ganó la competición ImageNet en 2012 con una diferencia en precisión del 11 % con respecto al algoritmo que quedó en segundo lugar.

#### 6.4.7.3. GoogLeNet

La arquitectura de GoogLeNet está basada en un módulo que se denomina **Inception** creado con la intención de reducir el coste computacional de las CNNs. Para ello se propone que en vez de construir una red muy profundas se realicen simultáneamente múltiples convoluciones en una sola capa. Con este modelo aparecen los primeros filtros de convolución  $1 \times 1$  encargados de reducir la profundidad del volumen de entrada manteniendo las dimensiones.

Con este modelo, se permitía realizar simultáneamente diversas operaciones sobre un volumen de entrada y finalmente se concatenaban los mapas de activación.




Figura 6.9.: Ejemplos de módulos Inception.

Con este nuevo módulo se desarrolló en 2015 la red GoogLeNet [SLJ<sup>+</sup>15], que consiguió ganar el concurso ImageNet con empate técnico con la red **VGG-19**. En vez de usar capas FC usaron la técnica de **golbal average pooling** mediante la cual reducían la dimensión de los tensores con convoluciones  $1 \times 1$ .




Figura 6.10.: Arquitectura de GoogLeNet usando módulos Inception.

Destacan las siguientes propiedades:

- Tiene un total de 27 capas de profundidad, por lo que aumenta notablemente la profundidad con respecto a sus antecesores.
- El uso de convoluciones  $1 \times 1$  con 128 filtros ayudan a reducir la dimensionalidad en lugar de usar capas FC.
- Contiene una capa FC con 1024 unidades y que alimenta una ReLU.
- Tiene una capa lineal con Softmax para clasificación multiclase.

#### 6.4.7.4. VGG-16

Supuso un gran salto en rendimiento con respecto a los modelos anteriores. Los principales cambios con modelos anteriores como AlexNet es que dejaron de usar filtros de grandes dimensiones en las primeras etapas de la red para pasar a usar solo filtros  $3 \times 3$ . Esto ahorra costes y permitía hacer una red más profunda [SZ14].

Destacan las siguientes propiedades:

- Consigue en Imagenet una precisión del 92.7%.
- Tiene unos 138 millones de parámetros entrenables que es más del doble de cualquiera de los modelos anteriores, lo que hace que VGG-16 sea muy lenta de entrenar.

#### 6.4.7.5. ResNet

Tras los modelos anteriores, todavía quedaba un problema que tenían las CNN sin resolver, y es que cuanto más profundas eran, más problema había con el cálculo de los gradientes, pues tendían a cantidades infinitesimalmente pequeñas. Es por ello que surge la arquitectura **ResNet** [HZRS16], que introduce cortes en la red conectando un tensor con el que había unas cuantas etapas atrás, a esto se le denomina **bloque residual**.

Con estos bloques residuales impedimos que los gradientes tiendan a cero rápidamente, con lo que podemos crear redes mucho más profundas. De hecho la versión de ResNet con 152 capas ganó el concurso ILSVRC 2015 siendo la red más profunda en aquel entonces.

## 6. Fundamentos Teóricos




Figura 6.11.: Arquitectura de VGG-16.




Figura 6.12.: Bloque residual de una ResNet. Como vemos, se suma el tensor  $x$  con el tensor  $\mathcal{F}(x)$  que surge unas etapas después. Imagen extraída de [HZRS16].




Figura 6.13.: Resumen de los ganadores del concurso ILSVRC hasta 2015 con la aparición de Resnet. Imagen extraída de [Fei17].



## 6.5. Autoencoders

Hasta ahora hemos visto qué son las CNN y su gran importancia en Deep learning en tareas de reconocimiento de objetos en imágenes. A continuación vamos a presentar un tipo de red que se emplea en tareas de *Aprendizaje no supervisado* y que será de gran importancia en nuestro trabajo. Se tratan de las redes conocidas como **Autoencoders**.

### 6.5.1. Introducción

Los **Autoencoders** [Der17] son un tipo específico de red cuya entrada “coincide” con su salida. Se encargan de reducir las imágenes de entrada a un vector perteneciente a un espacio vectorial latente y que idealmente codifica los elementos más relevantes en la imagen para posteriormente reconstruir la imagen a partir de este vector con la intención de que sea lo más parecida posible a la de entrada.

Los autoencoders tienen tres componentes principales:

- **Encoder:** Suele ser una subred que se encarga de codificar la entrada a un vector de un espacio vectorial latente.
- **Code:** es el vector que codifica la imagen de entrada.
- **Decoder:** se trata de una subred que reconstruye la imagen a partir del vector.

Como podemos ver, no se necesita ningún tipo de etiqueta para reconstruir las imágenes de entrada, por lo que este tipo de redes se emplean en tareas de *Aprendizaje no supervisado*.




Figura 6.14.: Esquema de un Autoencoder básico. Imagen extraída de [Der17].

Esta estructura ha ido evolucionando durante los últimos años, por lo que vamos a ver a continuación esta evolución hasta llegar a la red que emplearemos en nuestro trabajo, el **Adversarial Autoencoder**.

### 6.5.2. Evolución de los Autoencoders

#### 6.5.2.1. Generative Adversarial Networks (GANs)

Es una red cuyo fin es “crear nuevo contenido” y que sea lo más similar posible al contenido de la base de datos que usamos para entrenar la red. Para ello se pretende aprender la distribución de probabilidad que siguen los píxeles de las imágenes del dataset, por lo que el objetivo realmente sería el re generar nuevos valores aleatorios de la distribución de probabilidad que siguen las imágenes [Roc19a].

Para esta tarea suele emplearse una CNN denominada *Generative Network* que tiene como objetivo recibir una imagen o un vector aleatorio y producir como salida una imagen de




Figura 6.15.: Ejemplo de una Generative Network que pretende aprender la distribución de probabilidad de un conjunto de imágenes de perros. Imagen extraída de [Der17].

las mismas dimensiones que la de entrada que siga la distribución de probabilidad de las imágenes del dataset a nivel de **pixel**. Esta red tiene la estructura de un **Autoencoder**.

Por otro lado, se hace uso de una segunda CNN denominada *Discriminador*, que recibe un conjunto de imágenes del dataset e imágenes generadas por el *Generative Network* imagen de entrada y trata de clasificarlas en imágenes procedentes del dataset o imágenes generadas por la red. Por lo que el objetivo de la GAN en general podría resumirse en generar imágenes con la *Generative Network* que sean capaces de engañar al *Discriminador*, y para esto se pretende aprender lo mejor posible la distribución de probabilidad de las imágenes del dataset.




Figura 6.16.: Resumen del proceso de entrenamiento de una GAN. Imagen extraída de [Der17].




Figura 6.17.: Ejemplo de la arquitectura de una GAN para generar imágenes de dígitos manuscritos. Imagen extraída de [Ras20]

### 6.5.2.2. Variational Autoencoder (VAE)

Un VAE puede definirse como un autoencoder cuyo entrenamiento es regularizado para evitar el overfitting y asegurarse que el espacio vectorial latente tiene propiedades adecuadas para la generación de nuevos datos.

La principal diferencia entre el Autoencoder y el Variational Autoencoder es que en vez de codificar cada punto de entrada como un único punto, va a codificarlo como una distribución sobre el espacio latente buscando la distribución de los datos, no de los píxeles. El modelo de entrenamiento sería:

- La entrada se codifica como una distribución sobre el espacio vectorial latente.
- Un punto del espacio latente es muestreado por la distribución.
- Se decodifica el punto y se calcula el error de reconstrucción.
- Se usa backpropagation con el error anterior.




Figura 6.18.: Diferencia en el tratamiento de los datos por parte del encoder en una VAE y un Autoencoder clásico. Imagen extraída de [Roc19b].

El modo de proceder habitual es tomar las distribuciones de los datos codificados como normales, así puede devolverse la media y matriz de covarianzas que describen la Gaussiana. La razón por la que la entrada se codifica como una distribución es porque esto permite expresar de forma natural la regularización del espacio vectorial latente ya que las distribuciones que salen del codificador se forzarán a que sean lo más similar posible a una distribución normal estandar, este término regularizante se incluye en la función de coste como podemos ver en Figura 6.19. Para ello utiliza la divergencia de *Kulback-Leibler* (KL) como medida entre la diferencia entre dos distribuciones.

### 6.5.2.3. Adversarial Autoencoder(AAE)

Un Adversarial Autoencoder no es más que la unión de la arquitectura de un Autoencoder con el concepto de Adversarial Loss y el Discriminante introducido por la GAN. Por otro lado utiliza la idea del VAE para regularizar el espacio vectorial latente pero en lugar de la divergencia de KL emplea el adversarial loss.

Para ello se añade un nuevo componente que actúa como Discriminador y el Encoder actuará como Generador(a diferencia de las GANs, dónde la salida del Generador era la imagen, no el vector del espacio vectorial latente). Se selecciona una distribución a seguir por los




Figura 6.19.: Diferencia en la función de pérdida de un Autoencoder clásico (imagen superior) y una VAE (imagen inferior). Destacamos el término KL regularizante que pretende que las distribuciones de los datos sigan una normal estándar. Imagen extraída de [Roc19b].

vectores del espacio vectorial latente (generalmente una distribución normal estándar). Así, los vectores generados por el Encoder tratarán de engañar al Discriminador, que tendrá que discernir entre si proceden de la distribución elegida o no. En otras palabras, si el vector latente es una muestra aleatoria de la distribución deseada o bien es un vector generado por el ecoder.

Por lo tanto la arquitectura de un AAE presenta los siguientes componentes:

- **Encoder.** Tomará la entrada y la transformará en un vector latente de baja dimensión.
- **Decoder.** Tratará de reconstruir la imagen a partir del vector latente generado por el Encoder.
- **Discriminador.** Toma vectores de la distribución del espacio vectorial latente deseada (reales) y también vectores generados por el Encoder (fakes) y tratará de discernir entre si proceden de la distribución o no.

Esta arquitectura será la que emplearemos en nuestro proyecto, aunque presenta algunas variaciones que introduciremos cuando sea el momento.

## 6.6. Técnicas empleadas

En esta sección vamos a presentar las distintas técnicas que se emplearán en el trabajo durante el entrenamiento de la red que utilizaremos y que se presentará más adelante.




Figura 6.20.: Esquema de la arquitectura de un AAE. El Encoder sería la red a la que entra la imagen  $x$ , el vector  $z$  sería el vector latente, que sirve de entrada al Discriminador  $D_{gauss}$  y finalmente el vector  $z$  es la entrada del Decoder que reconstruye la imagen. Imagen extraída de [Ras20].

### 6.6.1. Few-shot Learning y Data Augmentation

Entendemos por **Few-shot learning** los problemas de AA en los que en la etapa de aprendizaje supervisado se dispone de muy pocos datos etiquetados. En nuestro caso disponemos de un dataset Forense con pocas imágenes etiquetadas, por ello lo consideramos un problema de few-shot learning.

Por otro lado, cuando se presentan este tipo de problemas se aplican técnicas de **data augmentation** que consisten en aumentar las imágenes de entrenamiento a base de *deformar* ligeramente, *rotar* o *trasladar* las imágenes existentes.



## **7. Estado del Arte**





## **8. Materiales y Métodos**



## **9. Planificación e implementación**



## 10. Experimentación



## **11. Conclusiones y Trabajos Futuros**





## A. Primer apéndice

Los apéndices son opcionales.

Archivo: `apendices/apendice01.tex`



## Glosario

La inclusión de un glosario es opcional.

Archivo: `glosario.tex`

$\mathbb{R}$  Conjunto de números reales.

$\mathbb{C}$  Conjunto de números complejos.

$\mathbb{Z}$  Conjunto de números enteros.



## Bibliografía

Las referencias se listan por orden alfabético. Aquellas referencias con más de un autor están ordenadas de acuerdo con el primer autor.

- [BM13] Joan Bruna and Stéphane Mallat. Invariant scattering convolution networks. *IEEE transactions on pattern analysis and machine intelligence*, 35(8):1872–1886, 2013. [Citado en pág. 21]
- [Der17] Arden Dertat. Applied deep learning. = <https://towardsdatascience.com/applied-deep-learning-part-3-autoencoders-1co83af4d798>, 2017. [Citado en págs. 65 and 66]
- [Fei17] Fei-Fei Li, Justin Johnson, Serena Young, Stanford University. cs231n. = <http://cs231n.stanford.edu/2017/syllabus.html>, 2017. [Citado en págs. 56, 59, 60, and 64]
- [GBC16] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>. [Citado en pág. 53]
- [Gon17] Rafael C. González. *Digital image processing / Rafael C. Gonzalez, Richard E. Woods*. Pearson Education Limited, Harlow, 4th ed., global ed. edition, 2017. [Citado en pág. 7]
- [Gup20] Aaryan Gupta. Evolution of convolutional neural network architectures. = <https://medium.com/the-pen-point/evolution-of-convolutional-neural-network-architectures-6b90d067e403>, 2020. [Citado en pág. 61]
- [HIWK15] María Isabel Huete, Óscar Ibáñez, Caroline Wilkinson, and Tzipi Kahana. Past, present, and future of craniofacial superimposition: Literature and international surveys. *Legal medicine*, 17 4:267–78, 2015. [Citado en pág. 47]
- [HZRS16] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016. [Citado en págs. 63 and 64]
- [J.B12] J.Bruna. Operators commuting with diffeomorphisms. *CMAP Tech. REport*, 2012. [Citado en pág. 21]
- [KSH12] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. *Advances in neural information processing systems*, 25, 2012. [Citado en págs. 61 and 62]
- [LBBH98] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998. [Citado en pág. 61]
- [LBH15] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *nature*, 521(7553):436–444, 2015. [Citado en pág. 25]
- [Low04] David G. Lowe. Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60, 2004. [Citado en pág. 26]
- [Mal00] Stéphane Mallat. *Une exploration des signaux en ondelettes*. Palaiseau: Les Éditions de l’École Polytechnique, 2000. [Citado en págs. 12 and 14]
- [Mal12] Stéphane Mallat. Group invariant scattering. *Communications on Pure and Applied Mathematics*, 65, 10 2012. [Citado en pág. 29]
- [PJDoMo6] University of Iowa Palle Jorgensen Department of Mathematics. Image decomposition using haar wavelet. = <https://homepage.divms.uiowa.edu/jorgen/Haar.html>, 2006. [Citado en pág. 14]

## Bibliografía

- [QV18] Stephen Quinn and Igor E Verbitsky. A sublinear version of schur’s lemma and elliptic pde. *Analysis & PDE*, 11(2):439–466, 2018. [Citado en pág. 36]
- [Ras20] Fathy Rashad. Adversarial auto encoder (aae). =<https://medium.com/vitrox-publication/adversarial-auto-encoder-aae-a3fc86f71758>,, 2020. [Citado en págs. 66 and 69]
- [Roc19a] Joseph Rocca. Understanding generative adversarial networks (gans). =<https://towardsdatascience.com/understanding-generative-adversarial-networks-gans-cd6e4651a29>,, 2019. [Citado en pág. 65]
- [Roc19b] Joseph Rocca. Understanding variational autoencoders (vae). =<https://towardsdatascience.com/understanding-variational-autoencoders-vae-f70510919f73>,, 2019. [Citado en págs. 67 and 68]
- [Ros88] Azriel Rosenfeld. Computer vision: basic principles. *Proceedings of the IEEE*, 76(8):863–868, 1988. [Citado en pág. 53]
- [SLJ<sup>+</sup>15] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 1–9, 2015. [Citado en pág. 63]
- [SSA17] Sagar Sharma, Simone Sharma, and Anidhya Athaiya. Activation functions in neural networks. *towards data science*, 6(12):310–316, 2017. [Citado en pág. 54]
- [SZ14] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*, 2014. [Citado en pág. 63]
- [TLF10] Engin Tola, Vincent Lepetit, and Pascal Fua. Daisy: An efficient dense descriptor applied to wide baseline stereo. *IEEE transactions on pattern analysis and machine intelligence*, 32:815–30, 05 2010. [Citado en pág. 26]
- [TY05] Alain Trounev and Laurent Younes. Local geometry of deformable templates. *SIAM Journal on Mathematical Analysis*, 37(1):17–59, 2005. [Citado en pág. 6]